O que é PLN?

<u>Aula 01</u> – Introdução ao Processamento de Linguagem Natural (PLN)

Eduardo Corrêa Gonçalves

02/03/2026

Sumário

Introdução

O que é PLN? O que se faz em PLN?

PLN – Uma Visão Geral

Exemplos de aplicações práticas (antigas e modernas)

Classificação dos Sistemas de PLN

Subáreas da PLN

Dimensões da Linguagem Humana

Paradigmas de PLN

Apresentação do Curso

Livros texto, material didático e critério de avaliação

Introdução (1/4)

- **O que é Processamento de Linguagem Natural (PLN) ?**
  - Campo de pesquisa que tem como objetivo investigar e propor métodos e sistemas de **processamento computacional** da **linguagem humana**.

"Vovó viu a uva"

[-2.0524, 4.5498 , -1.0387, -0.3042, ... , 3.2135, 0.9504]

* As definições apresentadas nessa aula foram retiradas de Caseli et al. (2024)

Introdução (2/4)

- **O que é Processamento de Linguagem Natural (PLN) ?**
  - Campo de pesquisa que tem como objetivo investigar e propor métodos e sistemas de **processamento computacional** da **linguagem humana**.

"Vovó viu a uva"

Frase em português

[-2.0524, 4.5498 , -1.0387, -0.3042, ... , 3.2135, 0.9504]

Mesma frase representada como um vetor numérico gerado por processamento computacional

* As definições apresentadas nessa aula foram retiradas de Caseli et al. (2024)

Introdução (3/4)

- **O que se faz em PLN?**
  - Buscam-se soluções para problemas que requerem o tratamento computacional de uma língua (português, inglês, coreano etc.).
    - língua escrita;
    - língua falada;
    - língua de sinais (ex.: Libras – Língua Brasileira de Sinais).
  - Apesar de a linguística reconhecer que existem textos escritos e textos falados, na PLN costuma-se utilizar a seguinte **convenção**:
    - língua escrita é chamada de texto.
    - língua falada é chamada de fala.
  - Esta **matéria** tem por **foco** o **processamento de texto** (língua escrita).

Introdução (4/4)

- **Por que "Natural" ?**
  - O adjetivo "natural" se refere às línguas faladas pelos humanos.
    - Para distinguir de linguagens:
      - matemáticas;
      - de programação;
      - visuais;
      - etc.
  - Nessa matéria, os termos "língua", "linguagem humana" e "linguagem natural" serão usados indistintamente.
  - Já o termo "linguagem" poderá ser usado para qualquer outro tipo de linguagem.

PLN – Exemplos de Aplicações Práticas (1/4)

- ***Mas* o que se faz *exatamente* em PLN? (1/4)**
  - Há um **grande número** de aplicações importantes !!!
  - Algumas são **tradicionais** e bastante **conhecidas**.

  - **Ex.1**: **correção ortográfica** → Verificar erros ortográficos em documentos e mensagens e sugerir correções

PLN – Exemplos de Aplicações Práticas (2/4)

- ***Mas* o que se faz *exatamente* em PLN? (2/4)**
  - Abaixo, mais um exemplo de aplicação **conhecida**.
  - **Ex.2**: **análise de sentimentos** → sistema "lê" um texto contendo uma opinião (ex.: post na Internet) e o classifica como "**positivo**" ou "**negativo**".

"O jantar estava delicioso. Isso sem falar no atendimento impecavel." → **Opiniao Positiva**

"O risoto do Restaurante XYZ chegou frio e estava super salgado!!! :-(" → **Opiniao Negativa**

PLN – Exemplos de Aplicações Práticas (3/4)

- ***Mas* o que se faz *exatamente* em PLN? (3/4)**
  - Outras aplicações são **mais recentes** e **pouco conhecidas**.
    - **Ex.1**: **correção automática de redações** → sistema "analisa" o texto de uma redação e atribui uma nota.
      - Por exemplo, há sistemas específicos para redações do ENEM*

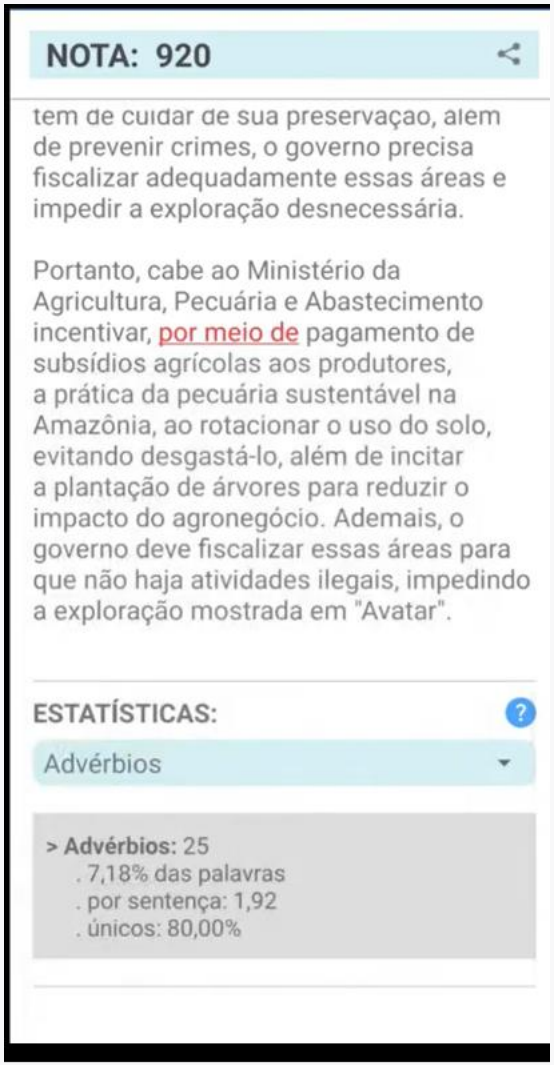

- https://jornal.usp.br/ciencias/usp-desenvolve-ferramenta-de-correcao-automatica-de-redacoes/

PLN – Exemplos de Aplicações Práticas (4/4)

- ***Mas* o que se faz *exatamente* em PLN? (4/4)**
  - Abaixo, um exemplo de aplicação **pouquíssimo conhecida**.

  - **<u>Ex.2</u>: detecção de persuasão em textos** → sistema "lê" um texto e verifica se o mesmo utiliza alguma técnica de persuasão (para promover um produto, uma agenda política etc.)
    - Assim, texto pode receber um "carimbo" de aviso de propaganda.

Appeal to Popularity (Bandwagon)

This technique gives weight to an argument or an idea by justifying it on the basis that allegedly 'everybody' (or the large majority) agrees with it or 'nobody' disagrees with it. As such, the target audience is encouraged to adopt the same idea by considering 'everyone else' as an authority, and to join in and take the same course of action.

Examples:

- *"Everyone is going to get the new smart phone when it comes out this weekend."*
- *"Would you vote for Putin as president? 70% say yes"*

- https://knowledge4policy.ec.europa.eu/text-mining/news-categorization-framing-persuasion-techniques-annotation-guidelines_en

Classificação dos Sistemas de PLN (1/5)

- Neste curso, serão apresentados:
  - **recursos**
  - **ferramentas**
  - **algoritmos**

  - ... utilizados pelas **aplicações** de PLN

    - ... construiremos “do zero” algumas aplicações baseadas nos algoritmos que serão estudados.

    - ... empregaremos recursos e ferramentas da **linguagem Python**.

Classificação dos Sistemas de PLN (2/5)

- **Relacionamento entre os conceitos**
  - Os sistemas de PLN podem ser classificados, quanto ao seu uso, como:
    - Ferramentas
    - Aplicações
    - Recursos

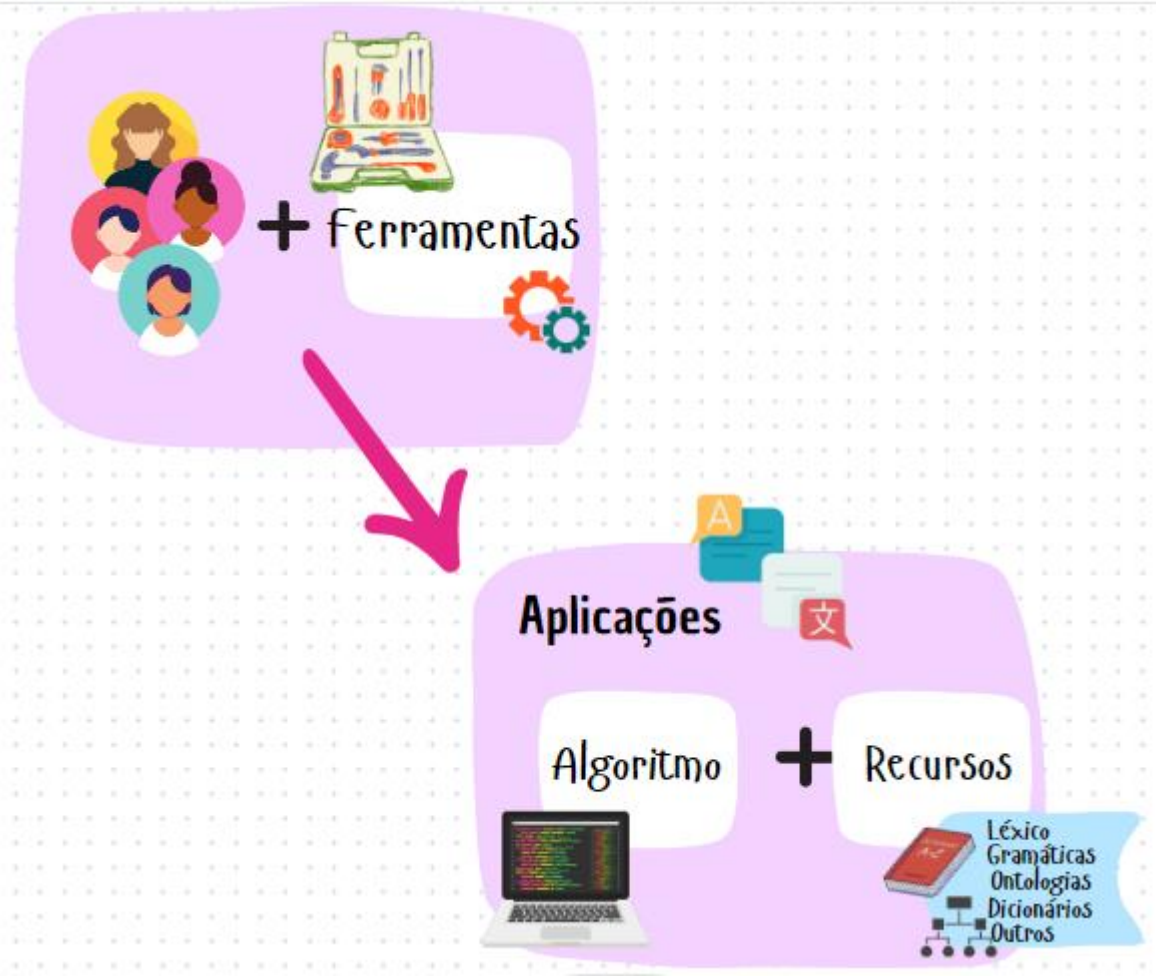

Relacionamento entre conceitos (Caseli et al., 2024)

Classificação dos Sistemas de PLN (3/5)

- **Aplicações**
  - Como visto em slides anteriores, as aplicações fornecem um resultado ao usuário, tendo uma entrada ou saída em linguagem natural
  - Normalmente empregam algoritmos e podem fazer uso de ferramentas e recursos.

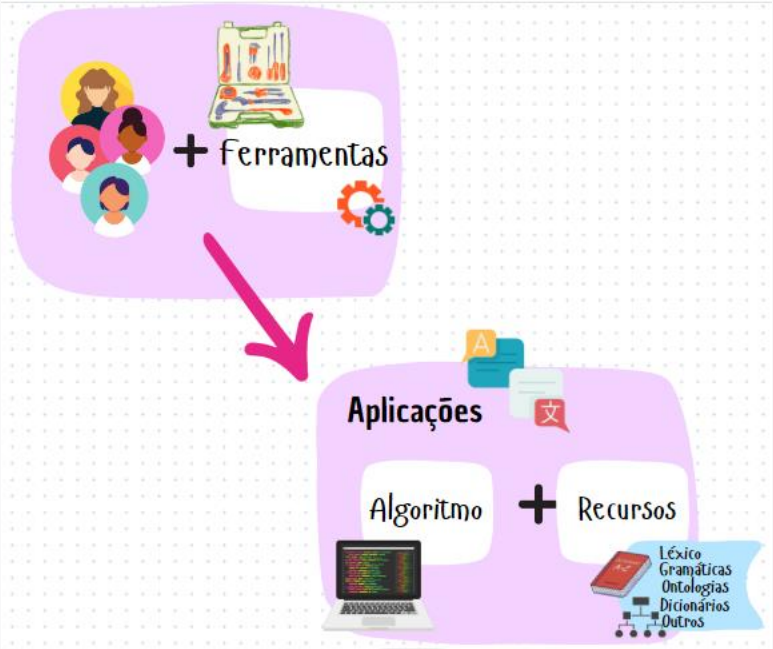

Exemplos
- corretor ortográfico ou gramatical - sistemas de recomendação em sites de e-commerce ou entretenimento - sistemas de recuperação de informação - sistemas de classificação ou segmentação de texto - sistemas de análise de sentimentos - sistemas de detecção de discurso de ódio - sumarizador automático - corretor de redações do enem - tradutor automático - assistentes virtuais / *chatbots* - sistemas de detecção de *fake news* - sistemas de deteção de persuasão - gerador de texto

Classificação dos Sistemas de PLN (4/5)

- **Recursos**
  - Fornecem informações linguísticas necessárias para que as aplicações consigam processar a língua de maneira adequada.

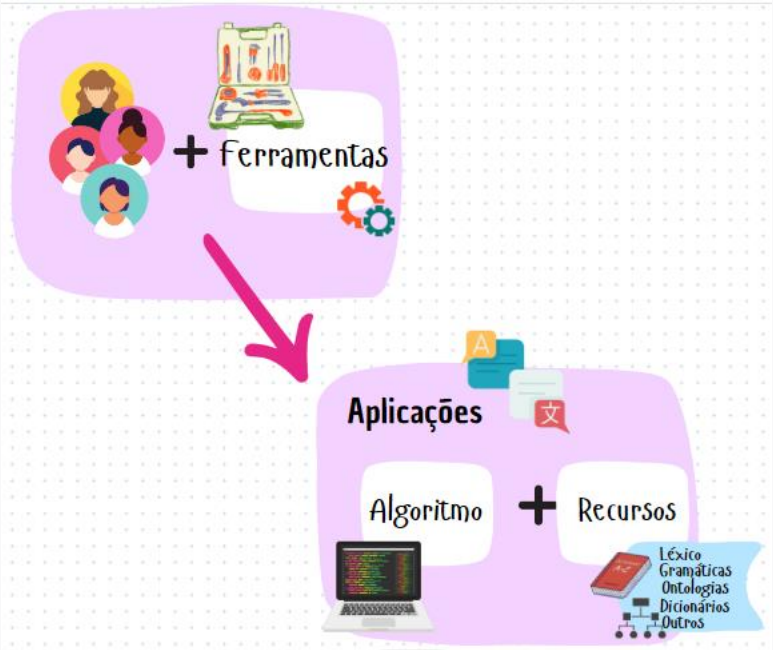

Exemplos
- léxicos (listas de palavras com informações associadas) da língua em geral ou de terminologia de domínio. - dicionários monolíngues ou bilíngues - (mais estruturados) taxonomias, ontologias, redes de sinônimos e antônimos - *corpus* (*datasets* linguísticos) anotados (para teste ou treinamento de algoritmos de aprendizado de máquina) - em formato matemático: modelos de língua estatísticos (probabilidades) ou neurais (pesos) para informar qual palavra deve ser a próxima num dado contexto

Classificação dos Sistemas de PLN (5/5)

- **Ferramentas**
  - Servem para auxiliar na construção de uma aplicação.

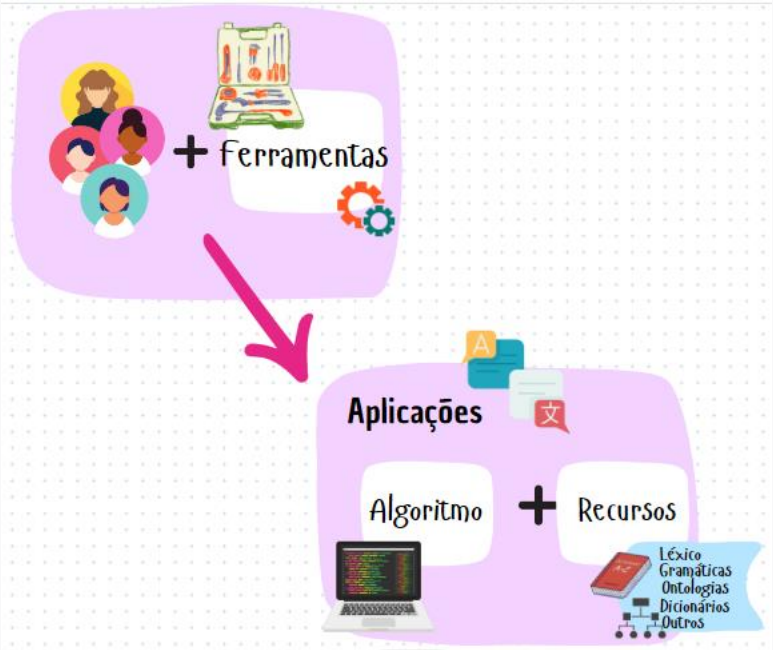

Exemplos
- segmentadores textuais em *tokens* (tokenizador), sentenças, parágrafos - *stemmers* (extratores de raiz de uma palavra, ex. “corr” de “correr”) - lematizadores (ex. “correr” de “corri”) - etiquetadores morfossintáticos (PoS *taggers*) para classe de palavras (verbo, substantivo, adjetivo, artigo, preposição, advérbio etc.) - etiquetadores semânticos e analisadores sintáticos parciais (*chunkers*) e completos (*parsers*) - componentes em kits de ferramentas (*toolkits*), como o NLTK e Spacy (usados nesse curso)

PLN e suas subáreas

- **A PLN é dividida em 2 subáreas:**
  - Interpretação da Linguagem Natural (*Natural Language Understanding – NLU*):
    - Cobre tudo que diz respeito ao processamento que visa à análise e interpretação da língua.
    - Ex.: analisar o texto de um e-mail e inferir se é spam ou não.
  - Geração da Linguagem Natural (*Natural Language Generation – NLG*):
    - Objetivo é a geração de linguagem natural.
    - Ex.: gerar respostas aos usuários de chatbot.
  - A NLU é usada para auxiliar a NLG e também é possível usar NLG para fazer NLU (veremos ao longo do curso...)

Dimensões da Linguagem Humana (1/5)

- **Subáreas que estudam o sistema linguístico**
  - A linguagem humana organiza-se em diferentes dimensões.

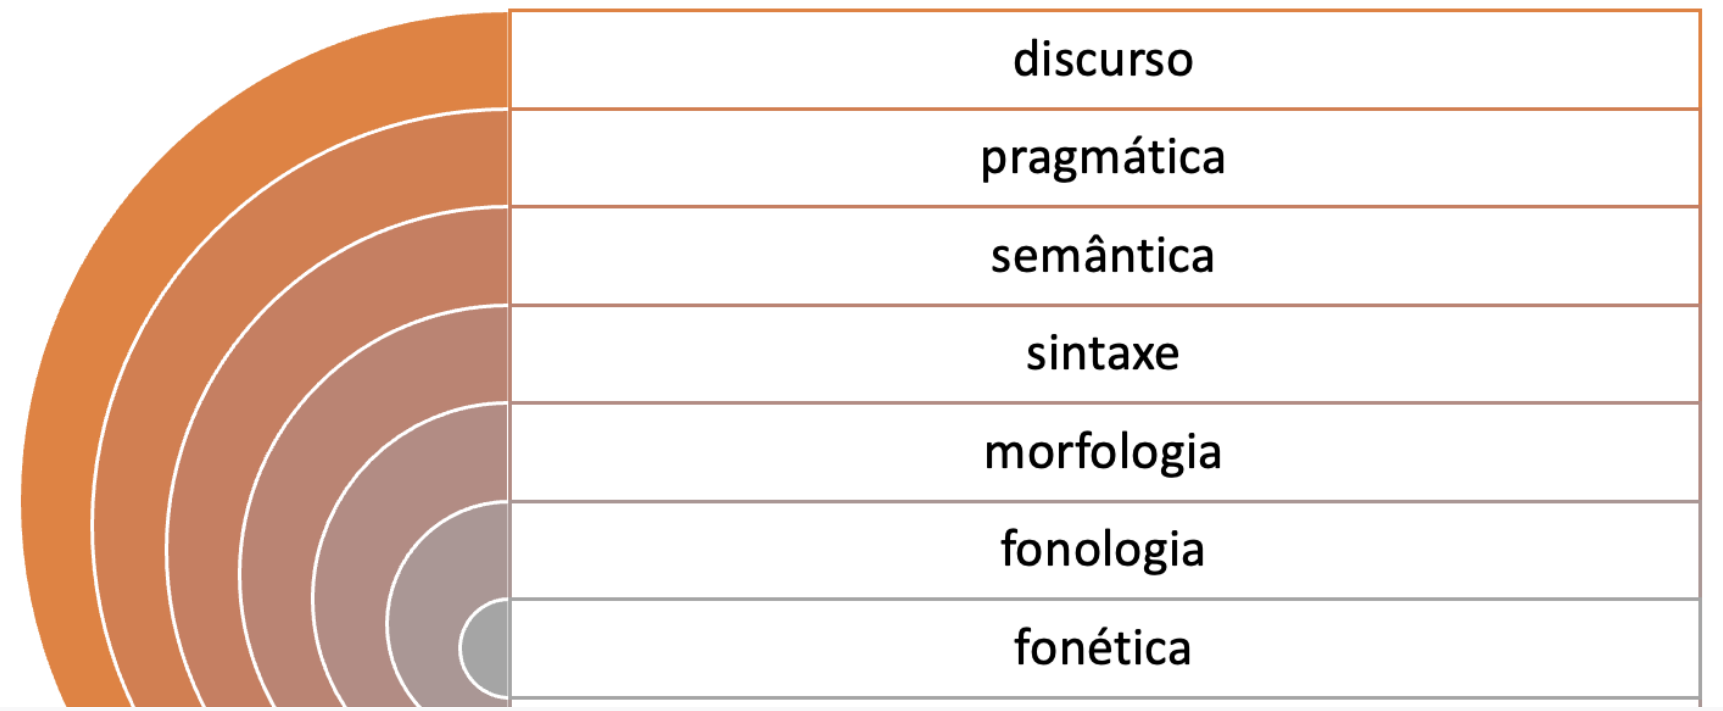

Representação das subáreas de estudo da linguagem (Caseli et al., 2024)

Dimensões da Linguagem Humana (2/5)

- **Subáreas que estudam o sistema linguístico**
  - Fonética e Fonologia: dimensões mais básicas, estudam os sons e sua organização.
  - Morfologia: como os morfemas se organizam para formar palavras.
  - Sintaxe: como as palavras se organizam em estruturas para formar sintagmas e orações.
  - Semântica: significado das palavras e frases.
  - Pragmática: como orações são utilizadas na interação para fins comunicativos específicos.
  - Discurso: dimensão mais abrangente, foco no texto como um todo, podendo fazer a análise das relações entre frases ou partes de um texto.

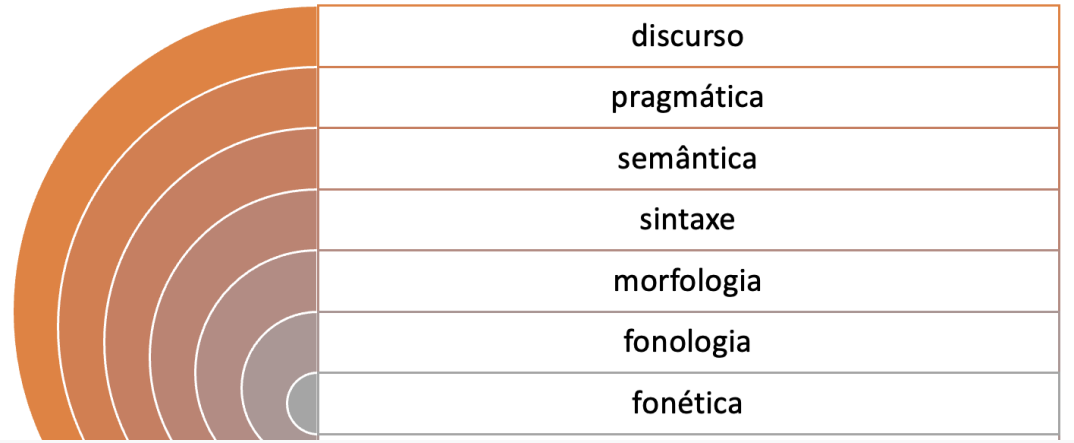

Dimensões da Linguagem Humana (3/5)

- **Subáreas que estudam o sistema linguístico**
  - Nesse curso, aumentaremos gradativamente a complexidade do tratamento da língua no PLN.
  - Como se trata de um **curso introdutório** com **foco no texto escrito**, começaremos na **morfologia** e "subiremos" **até o nível semântico**.

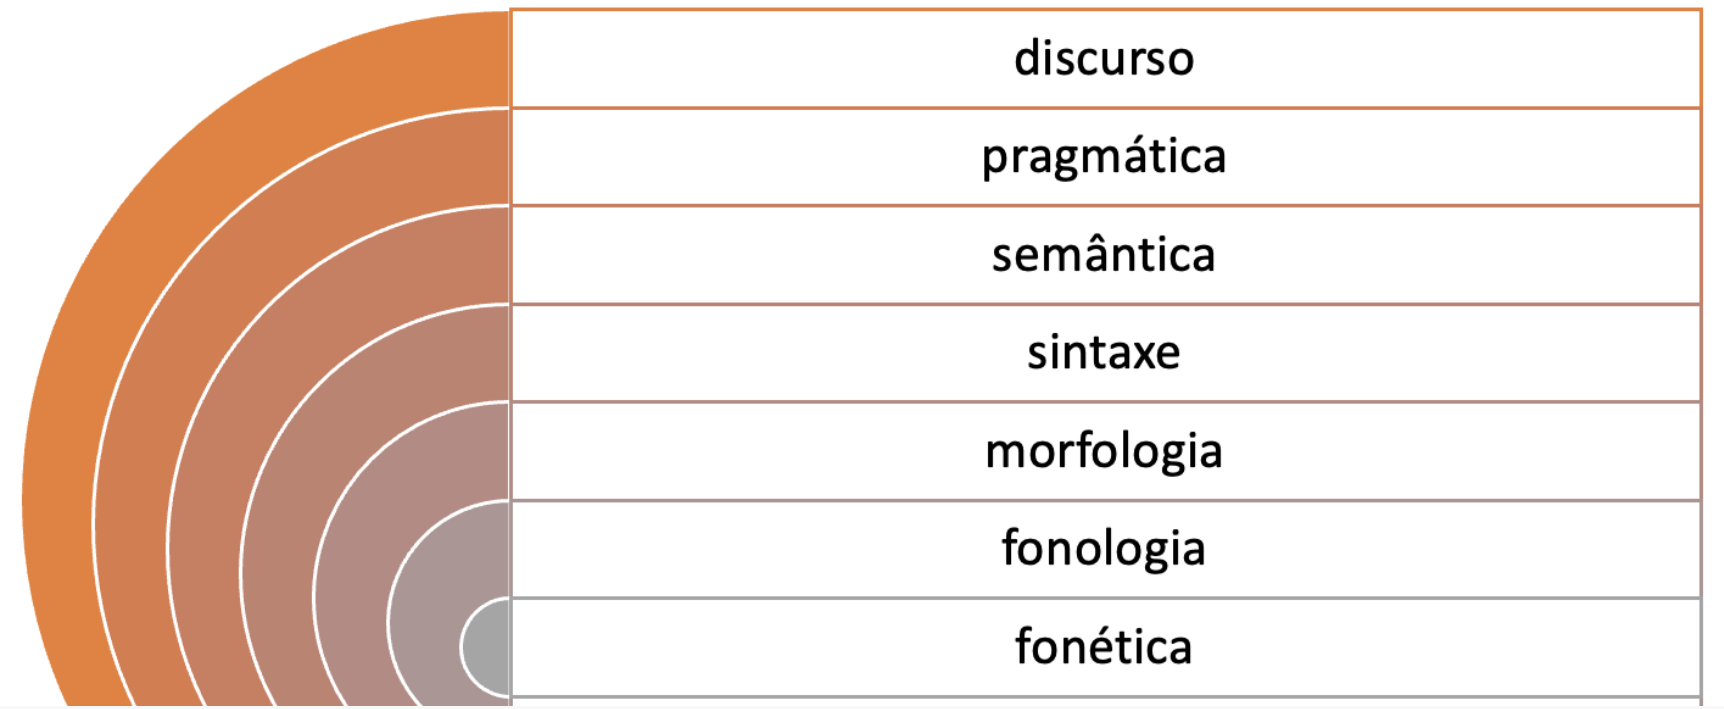

Dimensões da Linguagem Humana (4/5)

- **Qual a <u>dificuldade maior</u> em PLN?**
  - Há um consenso entre os pesquisadores de que se trata da apreensão do **significado** de um **texto**.

Dimensões da Linguagem Humana (5/5)

- **Qual a <u>dificuldade maior</u> em PLN?**
  - Há um consenso entre os pesquisadores de que se trata da apreensão do **significado** de um **texto**.
  - Para aplicações mais simples, isso nem sempre é relevante (**ex.**: correção ortográfica)...
  - ... Porém, para aplicações complexas é algo indispensável (**ex.**: detecção de persuasão).

Os Paradigmas de PLN (1/5)

- **Os 3 Paradigmas**
  - Há 3 diferentes paradigmas (categorias de abordagens) para a resolução de problemas de PLN:
    - Simbólico (predominante até a década de 1990)
    - Estatístico (predominante até 2010)
    - Neural (predominante nos dias atuais).
  - **IMPORTANTE**:
    - Embora os métodos neurais sejam mais empregados hoje em dia, os métodos simbólicos e estatísticos continuam sendo utilizados.
    - Os métodos simbólicos e estatísticos são mais simples e leves (demandam menos recursos computacionais), resolvendo muitas aplicações de forma eficaz.

Os Paradigmas de PLN (2/5)

- **Paradigma Simbólico**
  - Todo conhecimento sobre a língua é expresso explicitamente em formalismos, tais como léxicos, regras, linguagens lógicas etc.
    - **Ex.** (REGRA): "há concordância entre o gênero gramatical atribuído a um substantivo e o atribuído ao adjetivo que o acompanha"
      - "torta salgada" → **correto**
      - "torta salgado" → **incorreto**

- Predominou até meados dos anos 1990. Não foi abandonado !!!
- **Vantagem**: (i) regras são determinísticas (não há probabilidade de erro); (ii) representação compreensível ao ser humano.
- **Desvantagens**: (i) a língua é muito rica! Há uma explosão combinatorial de regras e suas exceções; (ii) em geral, menos eficaz que os outros 2 paradigmas.
- **Exemplos de métodos simbólicos**: distância de edição (algoritmo), WordNet (recurso).

Os Paradigmas de PLN (3/5)

- **Paradigma Estatístico**
  - Grandes conjuntos de texto são usados como fonte de conhecimento para ensinar máquinas.
  - Língua é representada em modelos probabilísticos aprendidos através da frequência de ocorrência das palavras.
    - **Ex.** fenômenos como a concordância entre substantivo e adjetivo passam a ser aprendidos a partir de exemplos de ocorrência:
      - "kiwi maduro", "tomate estragado" etc.

- Surgiu nos anos 1990, com o aumento da capacidade computacional (memória, processadores, paralelismo). Predominou até 2010 e não foi abandonado !!!
- **Vantagem**: (i) aprende os padrões sozinho; (ii) simples em comparação com os métodos neurais.
- **Desvantagens**: (i) depende de um corpus para aprender; (ii) como qualquer modelo probabilístico, sujeito a erros e incertezas.
- **Exemplos de métodos estatísticos**: TF-IDF, LDA, Naïve Bayes

Os Paradigmas de PLN (4/5)

- **Paradigma Neural**
  - Neste paradigma, grandes conjuntos de texto também são utilizados como fonte de conhecimento para ensinar máquinas.
    - Entretanto, os textos são processados por estruturas (arquiteturas e algoritmos) bastante complexas como as redes neurais profundas.
    - **Isto é**: a forma de aprendizado é diferente do paradigma estatístico, envolvendo várias camadas de unidades de processamento para reconhecer padrões recorrentes.

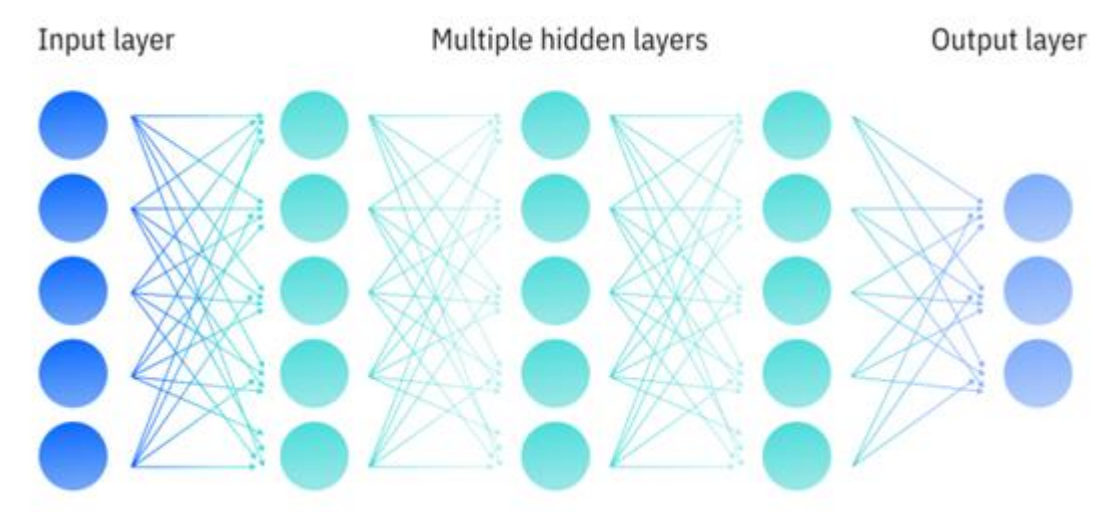

Os Paradigmas de PLN (5/5)

- **Paradigma Neural**
  - Surgiu mais recentemente. É o paradigma predominante atualmente.
  - **Vantagem**: (i) em geral, apresenta maior eficácia... proporcionou o avanço mais significativo na história da PLN e a consequente popularização dessa área de estudo.
  - **Desvantagem**: (i) demanda muitos recursos computacionais, incorrendo também em maior gasto de energia (se tornou um problema ecológico); (ii) devido à complexidade das arquiteturas, não é possível saber com base em quê o modelo foi aprendido.
  - **Exemplos de métodos neurais**: BERT, GPT, Arquitetura Transformer

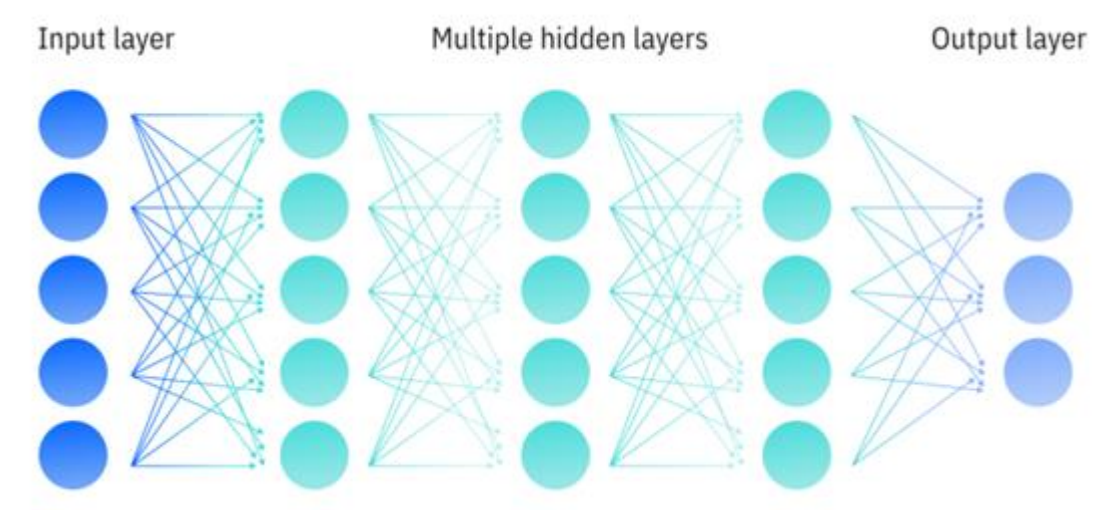

Apresentação do Curso (1/3)

- **Material Didático**
  - As aulas (PPTs) serão sempre disponibilizadas na minha pasta (Eduardo Corrêa Gonçalves) no site https://aulasence.ibge.gov.br/
  - Os programas serão compartilhados em notebooks no Google Colab.
  - **2 livros-texto online e gratuitos muito importantes** foram as fontes principais para a produção do conteúdo do curso:

Livro do Jurafsky • Mais técnico • Fonte principal	JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing**. 3. ed. *draft* [*s.l.*] : [*s.n.*], Jan. 2026. Disponível em: https://web.stanford.edu/~jurafsky/slp3/.
Livro das Brasileiras em PLN • Mais conceitual • Foco no Português	CASELI, H. M.; NUNES, M. G. V. (org.). **Processamento de Linguagem Natural**: Conceitos, Técnicas e Aplicações em Português. 3. ed. [*s.l.*] : BPLN, 2024. Disponível em: https://brasileiraspln.com/livro-pln/3a-edicao/.

  - Além desses livros, há material retirado de vários artigos científicos e de artigos com enfoque comercial. Estes serão sempre indicados nas referências (slide final de cada aula).

Apresentação do Curso (2/3)

Livro das Brasileiras em PLN (BPLN)

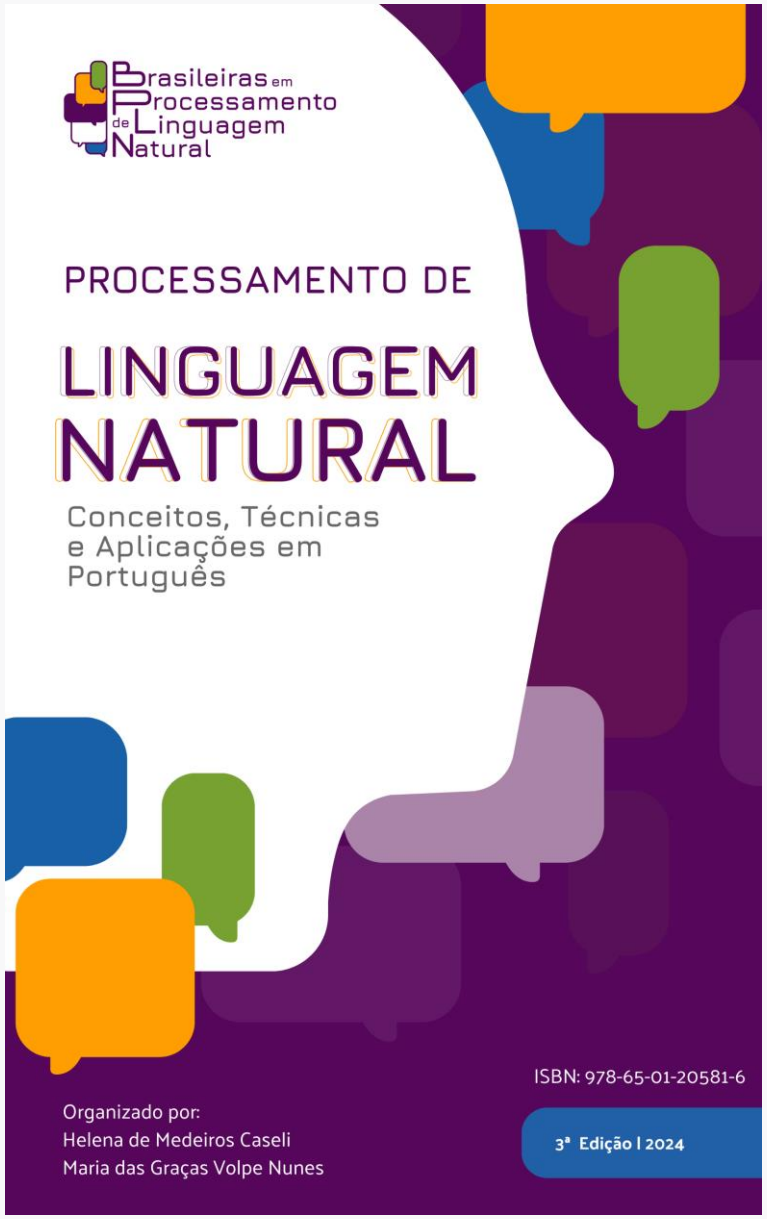

Livro do Jurafsky

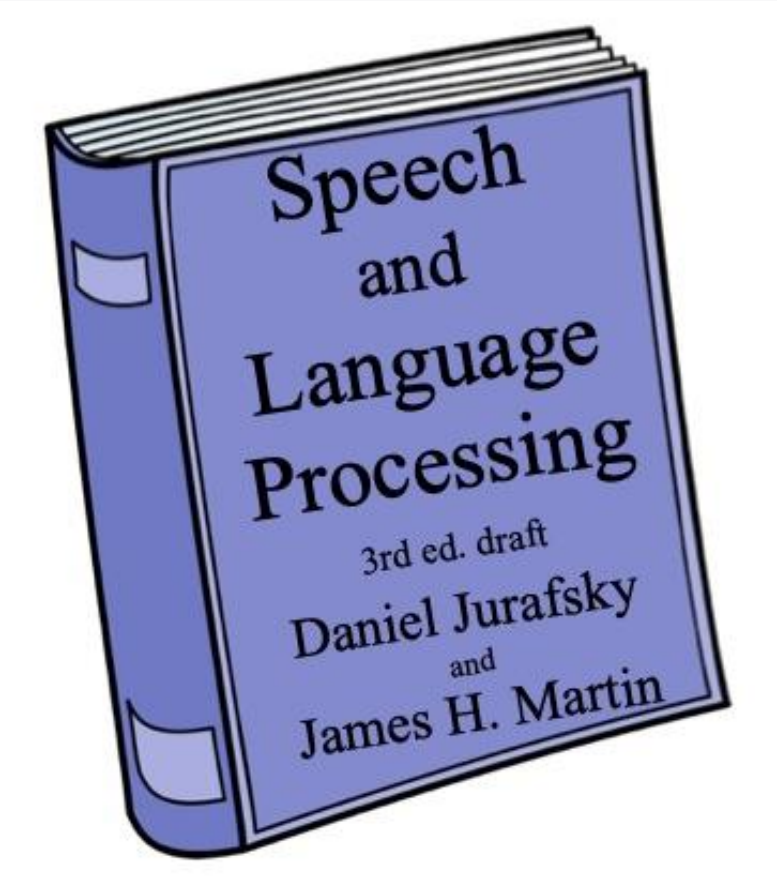

Apresentação do Curso (3/3)

- **Critério de Avaliação**
  - **NOTA DA VAE1**: teste dia 07/05 (matéria dada até a semana anterior)
  - **NOTA DA VAE2**: trabalho em **grupo de até 6 pessoas** – elaboração de modelo de machine learning (defesa da ideia + implementação)

  - Descrição do trabalho:
    - FASE 1 (abordagem estatística): definir um bom conjunto de variáveis para criar um modelo supervisionado ou não supervisionado a partir de uma base de dados textual (corpus)
      - Defender a ideia, basicamente, o motivo da escolha das variáveis

    - FASE 2 (abordagem estatística): criar e avaliar um modelo utilizando as variáveis definidas e uma técnica estatística clássica (ex.: regressão logística).

    - FASE 3 (abordagem neural): criar e avaliar um modelo neural a partir da mesma base de dados utilizando o BERTimbau. Comparar com os resultados do modelo criado com a abordagem estatística.

Referências

- CASELI, H. M.; NUNES, M. G. V.; PAGANO, A. O que é PLN?. In: CASELI, H. M.; NUNES, M. G. V. (org.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. [s.l.] : BPLN, 2024. Disponível em: https://brasileiraspln.com/livro-pln/3a-edicao/parte-introducao/cap-introducao/cap-introducao.html. Acesso em: 5 fev. 2026.

- CASELI, H. M.; NUNES, M. G. V. (org.). **Processamento de Linguagem Natural**: Conceitos, Técnicas e Aplicações em Português. 3. ed. [*s.l.*] : BPLN, 2024. Disponível em: https://brasileiraspln.com/livro-pln/3a-edicao/. Acesso em: 5 fev. 2026.

- JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing**. 3. ed. (Jan. 6, 2026 draft). [*s.l.*] : [*s.n.*], 2026. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 5 fev. 2026.