Naïve Bayes Multinomial para Classificação de Textos e de Sentimentos

A03 – Introdução ao Processamento de Linguagem Natural (PLN)

Eduardo Corrêa Gonçalves

09/03/2026

Sumário

Introdução

Conceitos Preliminares

- Regra do Produto
- Distribuição Conjunta de Probabilidades
- Independência Condicional

Naïve Bayes Multinomial (NB)

- Bag of Words
- As Suposições Ingênuas
- Computando as Probabilidades a priori e a posteriori
- Treinamento e Classificação – exemplo passo a passo
- Informações Complementares

Introdução (1/6)

- **O que é Naïve Bayes Multinomial (NB)?**
  - É um **algoritmo** de classificação. Na prática, é usado especialmente para **classificação de texto**.
    - **Isto é**: um algoritmo que, a partir de uma base de dados com textos pré-classificados, produz (ou "aprende") um modelo para classificar novos textos.
  - **Exemplo**: classificador de spam

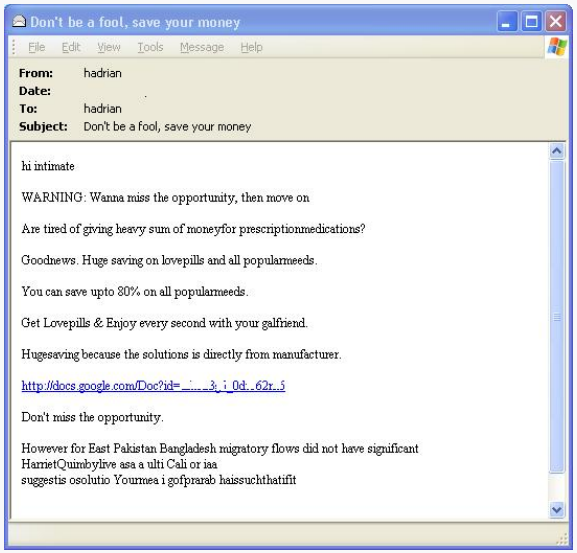

Entrada: **texto do e-mail**

Classificador
(modelo treinado)

{Normal** ou **Spam}

Saída: **uma das classes possíveis**

Introdução (2/6)

- **Algumas aplicações práticas do NB**
  - **(1) Análise de Sentimentos**
    - **Entrada**: texto contendo uma **opinião** sobre um produto, restaurante, filme, candidato etc.
    - **Classes possíveis:** opinião "**positiva**" ou "**negativa**"

"*O jantar estava delicioso. Isso sem falar no atendimento impecável.*" → **Classe: opiniao positiva**

"*O risoto do Restaurante XYZ chegou frio e estava super salgado!!! :-(*" → **Classe: opiniao negativa**

- Em *alguns problemas*, também existe a classe "**Opiniao neutra**".

Introdução (3/6)

- **Quais as principais aplicações práticas do NB ?**
  - **(2) Identificação de idioma (*language id*)**
    - Processo de identificar automaticamente (classificar) o idioma de um texto.
      - Muito utilizado pelos navegadores da Internet.
      - É comum o emprego de *n*-gramas de caracteres como *features*

C'era una volta un piccolo naviglio

C'era una volta un piccolo naviglio
C'era una volta un piccolo naviglio
C'era una volta un piccolo naviglio
che non sapeva, non sapeva navigar.

E pur si mise, si mise a navigar,
E pur si mise, si mise a navigar,
E pur si mise, si mise a navigar,
ma non poté, ma non poté piú navigar.

E dopo una, due, tre, quattro,
Cinque, sei, sette settimane
E dopo una, due, tre, quattro,
Cinque, sei, sette settimane
E dopo una, due, tre, quattro,
Cinque, sei, sette settimane
il naviglio, il naviglio naufragò.

Se questa storia poi non vi dà noia
Se questa storia poi non vi dà noia
Se questa storia poi non vi dà noia
la torneremo torneremo a cominciar.

Classe Italiano

Introdução (4/6)

- **Algumas aplicações práticas do NB**
  - **(3) Atribuição automática de tópicos (*topic tagging*)**
    - Processo de rotular um texto com um ou mais tópicos de acordo com os assuntos por ele abordados.

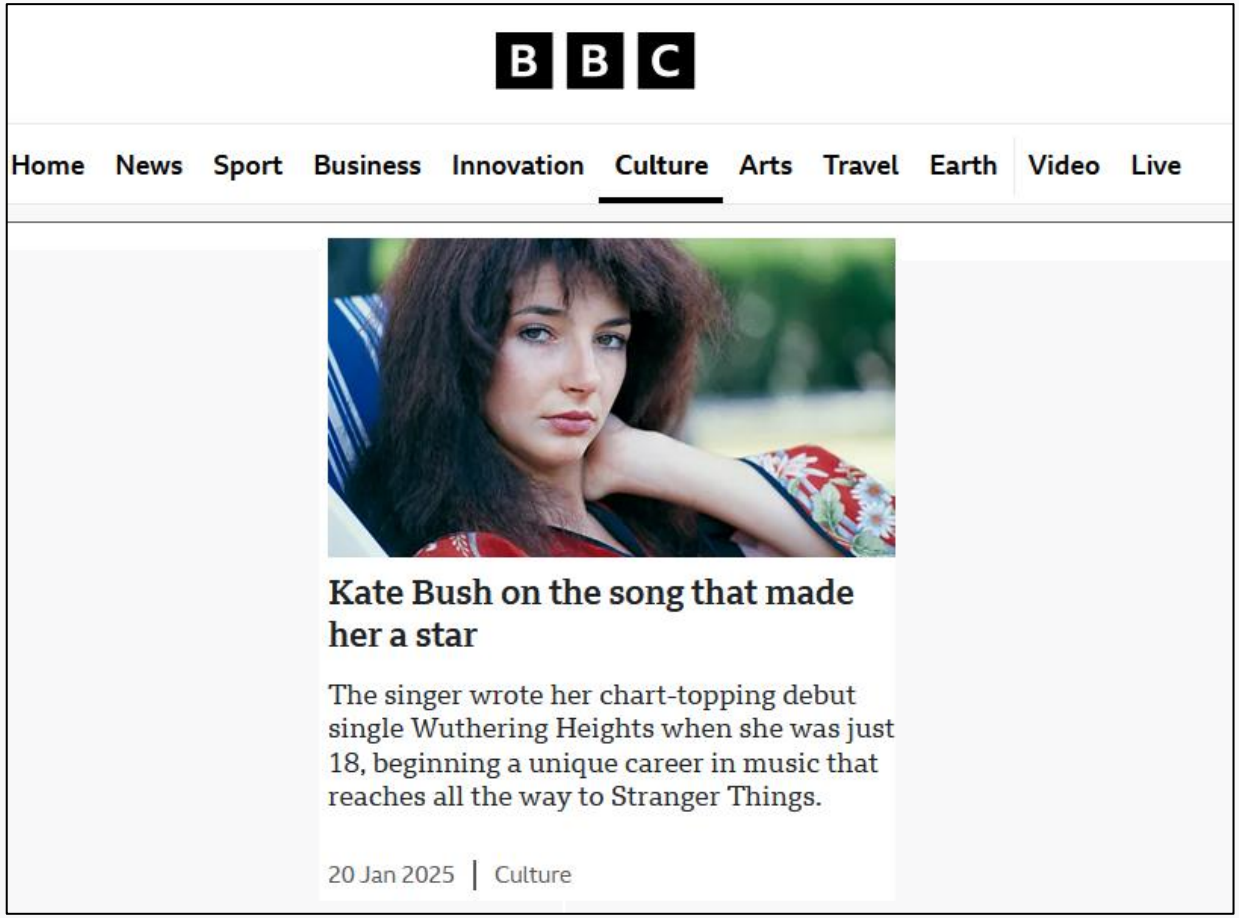

Classe: Cultura

Introdução (4/6)

- **Classificação de Texto com o NB**
  - A princípio, o NB pode ser usado em qualquer problema de classificação de texto.
  - Porém, para alguns problemas mais modernos, poderá ser menos eficaz.
  - **Ex.: Detecção de Posicionamento (*stance detection*)**
    - Processo de identificar se um comentário ou texto é favorável ou desfavorável em relação a algum tópico.
    - **Exemplo**: posição com relação à vacina da COVID

"*São visíveis os efeitos positivos da terceira dose de vacinação p/ idosos.*" → **Classe: favoravel**

"*Está provado que o melhor para prevenir é tomar muito líquido e se alimentar bem*" → **Classe: desfavoravel**

Introdução (6/6)

- **Qual o princípio básico do NB?**
  - Aplicar o **Teorema de Bayes** para estimar a classe mais provável de um texto.
  - A Fórmula de Bayes é derivada da fórmula "padrão" utilizada para calcular a probabilidade condicional:
    - $P(Y|X) = P(Y \wedge X) \div P(X)$
    - $P(Y|X) = P(X|Y) \times P(Y) \div P(X)$
  - **Onde**:
    - Y é o atributo classe (atributo do tipo categórico ou discreto)
    - X representa um conjunto de atributos preditivos: $X_1, X_2, ..., X_n$.
      - No caso do NB: as **palavras** que aparecem nos documentos

Conceitos Preliminares (1/9)

- **Conceitos utilizados pelo NB:**
  - Probabilidade Condicional e Teorema de Bayes
  - Regra do Produto
  - Independência Condicional
  - Distribuição Conjunta de Probabilidades

  - **Obs1**: observe que o NB **não se baseia apenas** no Teorema de Bayes, mas também nos demais conceitos acima.

  - **Obs2**: os conceitos são empregados para **validar** a maneira como a Fórmula de Bayes é aplicada no NB.
    - Melhor explicando: para que uma **fundamentação teórica** consistente seja oferecida.

Conceitos Preliminares (2/9)

- **Exemplo – Palavras que aparecem no resumo de filmes do gênero "Romance"**
  - Para facilitar, utilizaremos o BD abaixo para apresentar os conceitos.
    - Considere que trata-se de um BD com o texto de resumo de 10 filmes, onde "X" marca se a palavra ocorre ou não no texto.

Id Filme	*"amor" [A]*	*"relação" [R]*	*"gente" [G]*	*"casamento" [C]*
1	X	X	X	
2				X
3	X			
4	X	X		X
5		X		
6				X
7	X		X	
8	X	X		X
9		X		
10	X	X	X	X

Conceitos Preliminares (3/9)

- **Regra do Produto**
  - Também chamada de “regra da multiplicação” ou “regra da cadeia”.
  - É válida para qualquer conjunto de variáveis aleatórias.
  - Dado um conjunto de *n* variáveis $\{x_1, x_2, x_3, \ldots x_n\}$:

$$P(x_1 \wedge x_2 \wedge x_3 \wedge \ldots \wedge x_n) = P(x_1) \times P(x_2 \mid x_1) \times P(x_3 \mid x_1 \wedge x_2) \times \ldots \times P(x_n \mid x_1 \wedge x_2 \wedge x_3 \wedge \ldots \wedge x_{n-1})$$

Conceitos Preliminares (4/9)

- **Regra do Produto – BD de Resumos de Filmes**

Id Filme	*"amor"* *[A]*	*"relação"* *[R]*	*"gente"* *[G]*	*"casamento"* *[C]*
1	X	X	X	
2				X
3	X			
4	X	X		X
5		X		
6				X
7	X		X	
8	X	X		X
9		X		
10	X	X	X	X

- **$P(A \wedge R \wedge G \wedge C) = 1/10$**
- **$P(A \wedge R \wedge G \wedge C)$** $= P(A) * P(R|A) * P(G|A \wedge R) * P(C|A \wedge R \wedge G)$

$= 6/10 * 4/6 * 2/4 * 1/2 = 1/10$

Conceitos Preliminares (5/9)

- **Independência Condicional**
  - Na Teoria da Probabilidade, dizemos que a independência condicional ocorre sempre que:

$$P(X \mid A \wedge Y) = P(X \mid Y)$$

  - **Interpretação**: "se o objetivo é saber P(X), então é indiferente conhecer o valor de A caso o valor de Y seja conhecido."
    - X e Y são condicionalmente independentes dado A.
  - **Exemplo** (Charniak 1991):
    - P(Trovão | Chuva $\wedge$ Relâmpago) = P(Trovão | Relâmpago)
    - "se o objetivo é saber P(Trovão) , de nada importa saber que está chovendo, dado que é sabido que ocorreu um relâmpago".

Conceitos Preliminares (6/9)

- **Independência Condicional – BD de Resumos de Filmes**

Id Filme	*"amor"* *[A]*	*"relação"* *[R]*	*"gente"* *[G]*	*"casamento"* *[C]*
1	X	X	X	
2				X
3	X			
4	X	X		X
5		X		
6				X
7	X		X	
8	X	X		X
9		X		
10	X	X	X	X

- **P(R|A)**: Probabilidade de ter a palavra *"relação"* dado que tem "*amor*".
- P(R|A) = 4/6 =*66,67%*
- **P(R|A $\wedge$ G)**: Probabilidade ter a palavra *"relação"* dado que tem "*amor*" e *"gente"*
- P(R|A $\wedge$ G) = 2/3 =*66,67%*

- *Temos que:* P(R|A $\wedge$ G) **=** P(R|A)
  - R e A são **condicionalmente independentes** dado G.

Conceitos Preliminares (7/9)

- **Distribuição Conjunta de Probabilidades (*full joint distribution*)**
  - Atribui probabilidades para todos os possíveis eventos:

$A \wedge R \wedge G \wedge C$	$A \wedge \sim R \wedge G \wedge C$	$\sim A \wedge R \wedge G \wedge C$	$\sim A \wedge \sim R \wedge G \wedge C$
$A \wedge R \wedge G \wedge \sim C$	$A \wedge \sim R \wedge G \wedge \sim C$	$\sim A \wedge R \wedge G \wedge \sim C$	$\sim A \wedge \sim R \wedge G \wedge \sim C$
$A \wedge R \wedge \sim G \wedge C$	$A \wedge \sim R \wedge \sim G \wedge C$	$\sim A \wedge R \wedge \sim G \wedge C$	$\sim A \wedge \sim R \wedge \sim G \wedge C$
$A \wedge R \wedge \sim G \wedge \sim C$	$A \wedge \sim R \wedge \sim G \wedge \sim C$	$\sim A \wedge R \wedge \sim G \wedge \sim C$	$\sim A \wedge \sim R \wedge \sim G \wedge \sim C$

  - A soma de todas as probabilidades é igual a 1.

Conceitos Preliminares (8/9)

- **Distribuição Conjunta de Probabilidades (*full joint distribution*)**

$A \wedge R \wedge G \wedge C$	$A \wedge \sim R \wedge G \wedge C$	$\sim A \wedge R \wedge G \wedge C$	$\sim A \wedge \sim R \wedge G \wedge C$
$A \wedge R \wedge G \wedge \sim C$	$A \wedge \sim R \wedge G \wedge \sim C$	$\sim A \wedge R \wedge G \wedge \sim C$	$\sim A \wedge \sim R \wedge G \wedge \sim C$
$\mathbf{A \wedge R \wedge \sim G \wedge C}$	$\mathbf{A \wedge \sim R \wedge \sim G \wedge C}$	$\sim A \wedge R \wedge \sim G \wedge C$	$\sim A \wedge \sim R \wedge \sim G \wedge C$
$A \wedge R \wedge \sim G \wedge \sim C$	$A \wedge \sim R \wedge \sim G \wedge \sim C$	$\sim A \wedge R \wedge \sim G \wedge \sim C$	$\sim A \wedge \sim R \wedge \sim G \wedge \sim C$

- Se estiver disponível, posso obter qualquer probabilidade condicional ☺
  - Consequentemente, posso implementar qualquer classificador!!! ☺ ☺
  - **Ex:** um classificador que infere se um resumo contém a palavra "*relação*", em função das palavras "amor", "gente" e "casamento"
    - *Suponha um filme X com essas características*: $\{A \wedge \sim G \wedge C\}$
      - $P(\mathbf{R} \mid X) = P(A \wedge R \wedge \sim G \wedge C) \div P(A \wedge \sim G \wedge C)$
      - $P(\mathbf{\sim R} \mid X) = P(A \wedge \sim R \wedge \sim G \wedge C) \div P(A \wedge \sim G \wedge C)$

Conceitos Preliminares (9/9)

- **Distribuição Conjunta de Probabilidades (*full joint distribution*)**
  - Para computar qualquer probabilidade condicional precisaríamos da distribuição conjunta de probabilidades armazenada na memória do computador.
    - **ISSO É INTRATÁVEL NA PRÁTICA**, pois precisaríamos armazenar muitas informações.
    - Para *n* variáveis binárias, a distribuição conjunta de probabilidades requer o armazenamento de 2^n valores.
    - **Exemplo real - IMDb (base para classificação do gênero do filme em função do resumo)**: são 350.000 palavras (variáveis), o que exigiria $2^{350.000}$ valores em memória.
      - **IMPOSSÍVEL!!!!**

Conhecendo o Naive Bayes Multinomial (1/7)

- **Como criar um classificador de texto?**
  - Agora que os conceitos preliminares foram apresentados, vamos mostrar como criar um classificador NB*.
  - Para criar qualquer classificador, você precisa “apenas” de duas coisas:
    - Um bom **algoritmo de classificação**.
      - No nosso caso, o NB
    - Uma boa **base de dados de treinamento**.
      - Esta base deve conter **documentos classificados**, de acordo com **classes pré-definidas**.

** Todos os exemplos foram retirados de Jurafsky e Martin (2026)*

Conhecendo o Naive Bayes Multinomial (2/7)

- **Base de Dados de Treinamento**
  - **Exemplo:** BD para treinar um analisador de sentimentos que classifica a opinião sobre um filme como positiva ou negativa.
    - Contém 5 textos pré-classificados (comentários de 5 pessoas)
      - 3 negativos – **classe** ("-")
      - 2 positivos – **classe** ("+")
    - No jargão da PLN, chamamos um texto de **documento** (mesmo nesse caso onde o texto é um simples comentário).
    - Neste problema, temos $C = \{-, +\}$ (conjunto de classes pré-definidas)

comentário **(documento)**	**sentimento** **(classe)**
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Conhecendo o Naive Bayes Multinomial (3/7)

- **Bag of Words**
  - O NB trata cada texto do BD de treinamento como um “saco de palavras” (*bag of words – BOW*).
    - Conjunto de palavras, cuja **ordem não importa**.
    - **Apenas as frequências** são registradas.

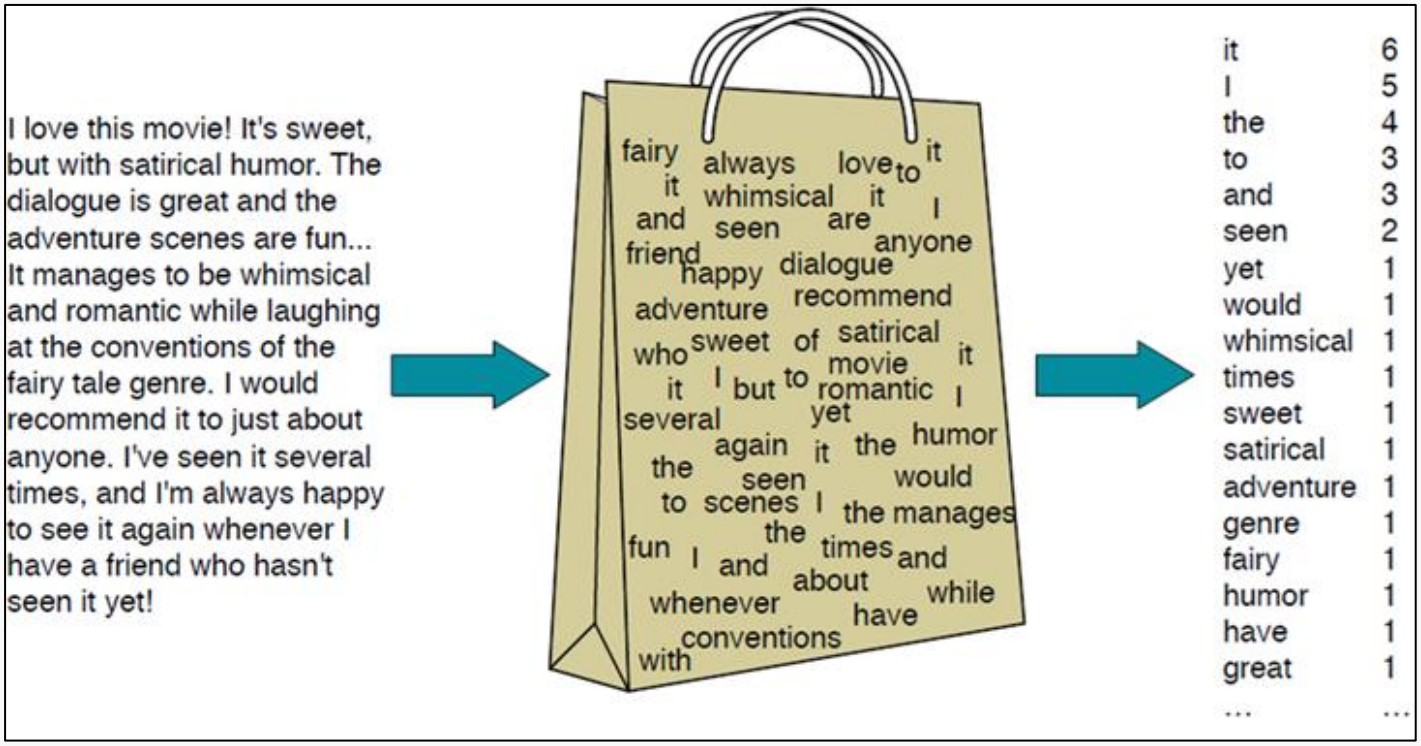

Conhecendo o Naive Bayes Multinomial (4/7)

- **Princípio básico do NB**
  - O NB é um classificador probabilístico
    - dado um **documento** *d*, dentre todas as **classes possíveis** $c \in C$...
    - ... o classificador retornará a **classe** $\hat{c}$ que apresentar a **máxima probabilidade a posteriori** dado o documento.

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}} P(c|d)$$

(*o "chapeuzinho" no* $\hat{c}$ *significa "estimativa da classe correta"*)

- O NB usará a fórmula de Bayes e os conceitos apresentados no início da aula para calcular a estimativa p/ cada classe:

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}} P(c|d) = \underset{c \in C}{\operatorname{argmax}} \frac{P(d|c)P(c)}{P(d)}$$

Conhecendo o Naive Bayes Multinomial (5/7)

- **Princípio básico do NB**

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}} P(c|d) = \underset{c \in C}{\operatorname{argmax}} \frac{P(d|c)P(c)}{P(d)}$$

  - Seja o exemplo de classificação de sentimentos, onde temos duas classes: "-" e "+"

  - Para classificar um documento *d*, seria preciso calcular 2 probabilidades:
    - Prob. do documento ser da classe ("-") (sentimento negativo)
    - P(*c* ="-"|*d*) = P(*d*|*c* ="-") x P(*c* ="-")

    - Prob. do documento ser da classe ("+") (sentimento positivo)
    - P(*c* ="+"|*d*) = P(*d*|*c* ="+") x P(*c* ="+")

  - A classe de *d* será aquela com maior valor estimado.

  - **IMPORTANTE**: veja que foi possível jogar o denominador P(*d*) fora porque ele é igual para o cálculo das 2 classes.

Conhecendo o Naive Bayes Multinomial (6/7)

- **Probabilidades a priori e a posteriori**
  - Ao fazer a classificação, escolhemos a classe com maior produto entre 2 probabilidades.
    - Probabilidade **a priori**.
    - Probabilidade **a posteriori**.

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}}\, P(c|d) = \underset{c \in C}{\operatorname{argmax}}\, \underbrace{P(d|c)}_{\text{Prob. a posteriori}} \times \underbrace{P(c)}_{\text{Prob. a priori}}$$

- **Features**
  - Podemos representar um documento como um conjunto das *n* **features** (palavras) que formam sua bag of words (nela temos palavra + freq.)

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}}\, P(c|d) = \underset{c \in C}{\operatorname{argmax}}\, P(f_1, f_2, \ldots, f_n|c) \times P(c)$$

Conhecendo o Naive Bayes Multinomial (7/7)

- **Fórmula Final**

$$\hat{c} = \underset{c \in C}{\operatorname{argmax}}\, P(c|d) = \underset{c \in C}{\operatorname{argmax}}\, P(f_1, f_2, \ldots, f_n|c) \times P(c)$$

  - O problema é que para calcular $P(f_1, f_2, \ldots, f_n \mid c)$, usando ou não a regra do produto, **precisaríamos** da **distribuição conjunta de probabilidades** em memória.

  - E isso é **impossível** !!!!
    - Vimos que não cabe na memória do computador !!!

  - **O que fazer** ?????
    - É aí que entram as suposições ingênuas do NB.

Suposições Ingênuas (1/4)

- **NB e suas suposições ingênuas**
  - O NB baseia-se em duas “suposições ingênuas”.
  - Elas são utilizadas para que seja possível estimar $P(c|d)$ de acordo com a seguinte estratégia:

    1. Empregando uma **fórmula simples**;
    2. Respeitando a **Teoria da Probabilidade**;
    3. Empregando uma **técnica computacional factível e eficiente** *(distante da intratável distribuição conjunta de probabilidade)*.

Suposições Ingênuas (2/4)

- **A Suposição Ingênua I** (ou suposição ***bag of words***)

  "A posição de uma palavra no documento não importa. Basta registrar sua frequência" .

  - Assim, o NB trata cada texto como uma "saco de palavras" (*bag of words*), conforme ilustrado na imagem abaixo.

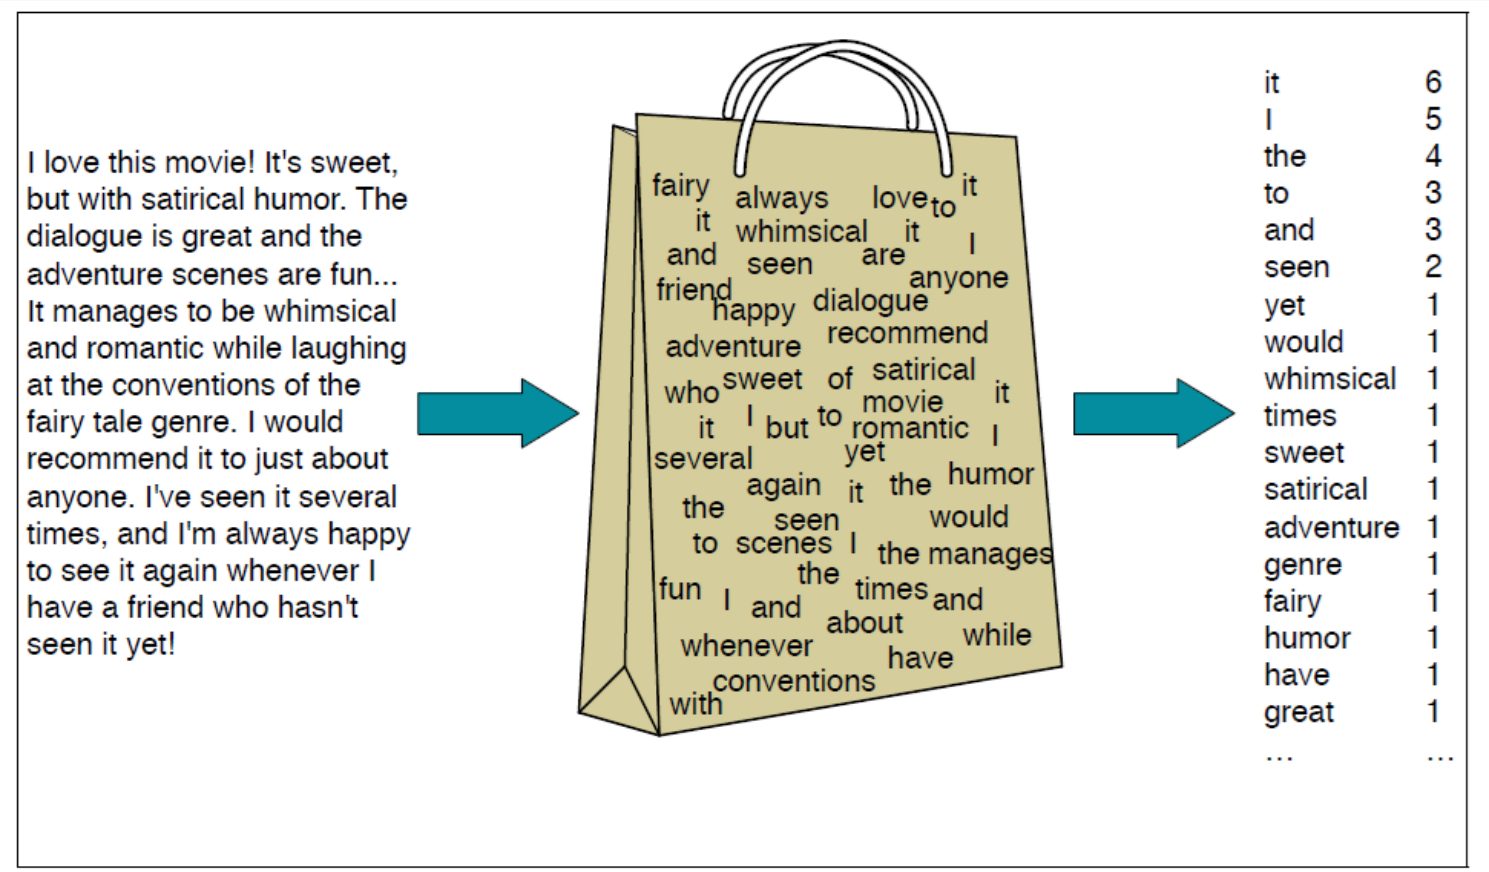

Suposições Ingênuas (3/4)

- **A Suposição Ingênua II (independência condicional)**

  "O efeito do valor de uma *feature* sobre o atributo classe é independente do valor das outras *features*".

  - Em outras palavras, ele assume que qualquer feature f_i e o atributo classe c são condicionalmente independentes dada outra feature f_j qualquer.

    - Isso quase nunca é real na prática.

    - Essa é a suposição ingênua mais importante. Sem ela, não há como empregar uma fórmula simples para estimar a classe de um documento.

Suposições Ingênuas (4/4)

- **A Suposição Ingênua II (independência condicional)**
  - Queremos estimar a prob. do documento *d* composto por *n* features ser da classe *c* usando a fórmula:
    - $P(c \mid d) = P(c) \times P(f_1, f_2, ..., f_n \mid c)$
  - Como *c* é o atributo classe e $f_1, f_2, ..., f_n$ são as *n* features da bag of words do documento *d* vamos reescrever usando a regra da multiplicação:
    - $P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c \wedge f_1) \times \ldots \times P(f_n \mid c \wedge f_1 \wedge \ldots \wedge f_{n-1})$
  - **Aplicando** a **Suposição Ingênua II**, vamos considerar que *c* e qualquer feature f_i são condicionalmente independentes dada outra feature f_j.
    - Assim podemos reescrever a fórmula...

$$P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times P(f_3 \mid c) \times \ldots \times P(f_n \mid c)$$

    - ... E chegamos em algo viável para o armazenamento em memória!

Obtendo P(c) e P(f_i | c) (1/3)

- **Fórmula final**

$$P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times P(f_3 \mid c) \times \ldots \times P(f_n \mid c)$$

  - Veja que precisamos das seguintes probabilidades para usar a fórmula:
    - P(c): probabilidade a priori do documento ser da classe c
    - P(f_i | c): probabilidade a posteriori do documento possuir a feature f_i dado que é da classe c.
  - **Como podemos estimar essas probabilidades?**
    - Elas são estimadas a partir da base de dados de treinamento.
    - *Veja nos slides a seguir !*

Obtendo P(*c*) e P(f_i | *c*) (2/3)

- **P(*c*) – probabilidade a priori do doc ser da classe *c***
  - Sejam:
    - N_c: número de documentos da classe *c* no BD de treinamento
    - N_{doc}: número total de documentos nessa base
  - Assim, P(*c*) pode ser calculado por:
    - $P(c) = N_c \div N_{doc}$
  - No BD abaixo: P(c = "-") = 3/5 e P(c = "+") = 2/5

comentário (documento)	**sentimento (classe)**
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Obtendo P(c) e P(f_i | c) (3/3)

- **P(f_i | c) – probabilidade a posteriori do doc ser da classe c dada feature f_i**
  - Computamos P(f_i | c) como a fração de vezes que a palavra i aparece dentre todos os documentos da classe c.
  - **Exemplo**: P("the" | +) = 2 / 9
    - Total de palavras em todos os docs da classe **+** = 9 (denominador da fórmula)
    - Frequência da palavra "the" = 2 nesses docs (numerador da fórmula)

comentário (documento)	**sentimento** (classe)
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Exemplo Passo a Passo (1/13)

- **Treinamento e Classificação com o NB**
  - Vamos demonstrar o passo a passo para treinar e utilizar um modelo NB.
  - Faremos com um exemplo hipotético de classificação de sentimentos (Jurafsky e Martin, 2026).
    - Considere a base de dados de treinamento já apresentada em slides anteriores, contendo comentários de 5 pessoas sobre um filme, sendo 3 negativos ("-") e 2 positivos ("+")

comentário	sentimento (classe)
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Exemplo Passo a Passo (2/13)

- **<u>Passo 1 do treinamento</u>: pré-processamento**
  - Antes de iniciar o treinamento, cada texto precisa ser convertido para uma *bag of words*.

comentário	sentimento (classe)
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

comentário	sentimento (classe)
{boring: 1, just: 1, plain: 1}	-
{and: 1, energy: 1, entirely: 1, lacks: 1, predictable: 1}	-
{and: 1, few: 1, laughs: 1, no: 1, surprises: 1, very: 1, }	-
{powerful: 1, very: 1}	+
{film: 1, fun: 1, most: 1, of: 1, summer: 1, the: 2}	+

Exemplo Passo a Passo (3/13)

- **Passo 2 do treinamento: geração do modelo**
  - Treinar um modelo NB significa computar uma tabela de frequências em memória.
    - Ela **resume o BD de treinamento**, com as informações suficientes para computar $P(c \mid d)$ de acordo com a "fórmula simples"
    - Essa tabela **é** o modelo NB !!!
  - Veja o resultado no slide a seguir

Exemplo Passo a Passo (4/13)

comentário	sentimento (classe)
{boring: 1, just: 1, plain: 1}	-
{and: 1, energy: 1, entirely: 1, lacks: 1, predictable: 1}	-
{and: 1, few: 1, laughs: 1, no: 1, surprises: 1, very: 1, }	-
{powerful: 1, very: 1}	+
{film: 1, fun: 1, most: 1, of: 1, summer: 1, the: 2}	+

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Exemplo Passo a Passo (5/13)

- **Classificação de um novo documento**
  - Basta pegar valores da tabela e plugar na fórmula:

$$P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times P(f_3 \mid c) \times \ldots \times P(f_n \mid c)$$

  - No caso da classificação de sentimentos, devemos estimar as probabilidades de c="+" e c="-", considerando as features do novo doc. *d* a ser classificado (basicamente, a bag of words desse texto).
  - Devemos plugar na fórmula apenas os componentes f_i referentes às **palavras que aparecem no texto** a ser classificado.
    - As demais palavras do vocabulário não precisam ser usadas.

Exemplo Passo a Passo (6/13)

- **Classificação de um novo documento**
  - Seja o novo texto (a ser classificado): *d = "predictable with no fun"*
  - **PASSO 1 da classif.**: transformar esse texto para um bag of words
    - Como o modelo **não conhece a palavra** "**with**" (ela não estava em nenhum dos textos de treinamento), ela vai ser **jogada fora**.
    - *"predictable with no fun"* → {fun: 1, no: 1, predictable: 1}

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Exemplo Passo a Passo (7/13)

- **<u>PASSO 2 da classificação</u>: correção de Laplace**
  - *"predictable with no fun"* → Veja o modelo! A palavra "fun" nao ocorreu com textos da classe "-" no BD de treinamento
    - Ou seja: P(Y = "-" | fun) = 0.
  - Com isso, o valor 0 vai entrar como termo da multiplicação, gerando 0 no resultado da estimativa dessa classe.
  - De maneira análoga, "no" e "predictable" não ocorreram na classe "+".

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Exemplo Passo a Passo (8/13)

- **<u>PASSO 2 da classificação</u>: correção de Laplace**
  - A solução é realizar a correção de Laplace ao calcular cada $P(c \mid d)$.
  - Isso é feito da seguinte forma. Para qualquer palavra envolvida na classificação:
    - Somamos 1 ao numerador; e
    - 20 ao denominador (pois esse é o tamanho do vocabulário). Veja no slide a seguir.

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Exemplo Passo a Passo (9/13)

- **<u>PASSO 2 da classificação</u>: correção de Laplace**

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \qquad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \qquad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \qquad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
- (3)	2	1	1	1	1	0	0	1	1	1	0	1	0	1	0	1	0	1	0	1
+ (2)	0	0	0	0	0	1	1	0	0	0	1	0	1	0	1	0	1	0	2	1

Exemplo Passo a Passo (10/13)

- **<u>PASSO 3 da classificação</u>: classificando o novo documento**
  - *d = "predictable with no fun"* → {fun: 1, no: 1, predictable: 1}

$$P(-) = \frac{3}{5} \qquad P(+) = \frac{2}{5}$$

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \qquad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \qquad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \qquad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

Est.1: P(*c* = "-" | *d*)= 3/5 x 2/34 x 2/34 x 1/34 = 6.1 x 10^{-5}

Est.2: P(*c* = "+" | *d*)= 2/5 x 1/29 x 1/29 x 2/29 = 3.2 x 10^{-5}

Exemplo Passo a Passo (11/13)

- **<u>PASSO 3 da classificação</u>: classificando o novo documento**
  - *d = "predictable with no fun"* → {fun: 1, no: 1, predictable: 1}

$$P(-) = \frac{3}{5} \qquad P(+) = \frac{2}{5}$$

$$P(\text{“predictable”}|-) = \frac{1+1}{14+20} \qquad P(\text{“predictable”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“no”}|-) = \frac{1+1}{14+20} \qquad P(\text{“no”}|+) = \frac{0+1}{9+20}$$

$$P(\text{“fun”}|-) = \frac{0+1}{14+20} \qquad P(\text{“fun”}|+) = \frac{1+1}{9+20}$$

Como a estimativa para negativo e maior, o doc e classificado como negativo

Est.1: P(*c* = "-" | *d*)= 3/5 x 2/34 x 2/34 x 1/34 = **6.1 x 10^{-5}**

Est.2: P(*c* = "+" | *d*)= 2/5 x 1/29 x 1/29 x 2/29 = 3.2 x 10^{-5}

Exemplo Passo a Passo (12/13)

- **Denominador – felizmente ele é jogado fora...**
  - Em nosso exemplo, *c* pode ter os valores "-" (opinião negativa) ou "+" (opinião positiva).
    - Por isso, para qualquer texto *d*, calculamos os dois casos
  - A fórmula de Bayes é na verdade: $P(c|d) = (P(d|c) \times P(c)) \div P(d)$
    - Então, para cada classe teríamos:

$$P(\mathbf{c = \text{“-”}} \mid d) = (P(c=\text{“-”}) \times P(f_1 \mid c=\text{“-”}) \times P(f_2 \mid c=\text{“-”}) \times \ldots \times P(f_n \mid c=\text{“-”})) \div P(d)$$

$$P(\mathbf{c = \text{“+”}} \mid d) = (P(c=\text{“+”}) \times P(f_1 \mid c=\text{“+”}) \times P(f_2 \mid c=\text{“+”}) \times \ldots \times P(f_n \mid c=\text{“+”})) \div P(d)$$

  - Mas veja que, para ambas as estimativas, o denominador é o mesmo: $P(d)$. Então ele pode ser desconsiderado, e assim o fizemos.
    - Na prática, **seria impossível usar $P(d)$**, pois precisaríamos ter distribuição conjunta de probabilidade das features (palavras) em memória para qualquer texto possível com as palavras do vocabulário.

Exemplo Passo a Passo (13/13)

- **Normalização**
  - Para o resultado ficar mais bonito para o usuário, as ferramentas costumam normalizar com o intuito de gerar percentuais para a estimativa de cada classe.
  - $P(c = \text{“-”} \mid d) = 6.1 \times 10^{-5} \div (6.1 \times 10^{-5} + 3.2 \times 10^{-5}) =$ **65,59%**
  - $P(c = \text{“+”} \mid d) = 3.2 \times 10^{-5} \div (6.1 \times 10^{-5} + 3.2 \times 10^{-5}) = 34{,}41\%$
  - Esses são os resultados normalmente apresentados ao usuário de um software que classifica com o NB.
    - *O “pobre” do usuário nem imagina que simplificações baseadas nas suposições ingênuas foram aplicadas...*

n-Gramas como *features*

- **Além das palavras**
  - Normalmente, utilizamos as palavras como *features* para o aprendizado de um modelo NB.
  - Porém, também é possível utilizar *n*-gramas (seja de palavras ou de caracteres).
    - Nesse caso, o modelo seria uma tabela de frequências de *n*-gramas em vez de palavras.
  - É possível até mesmo combinar as duas coisas.
    - O modelo sendo uma tabela com frequências das palavras, dos bigramas, dos trigramas etc.

Prós e Contras (1/3)

- **NB – Pontos positivos**

☺ **Simplicidade** – o modelo de classificação é apenas uma tabela de frequências.

- Além disso, o algoritmo é fácil de entender e implementar.
- Por isso, é uma boa porta de entrada p/ quem deseja estudar aprendizado de máquina supervisionado.

☺ **Baixo custo computacional** – O treinamento é feito com uma única passada no banco de dados.

- Na hora de classificar um novo texto, só preciso considerar as palavras desse novo texto
- *As outras palavras presentes na tabela gerada pelo modelo podem ser ignoradas*.

☺ **Caixa branca** – Ao contrário dos métodos neurais, é possível identificar o motivo pelo qual uma dada classe foi atribuída a um novo documento.

Prós e Contras (2/3)

- **NB – Pontos negativos**

☹ Em geral, **menos eficaz** que os métodos neurais:

- Porém, funciona surpreendentemente bem em diversos problemas

☹ Pode levar a ocorrência de ***underflow***

- *Mas isso pode ser tratado, como mostra o próximo slide*

☹ **Ignora o conceito** (**semântica**), considera apenas as frequências das palavras para criar o modelo.

Prós e Contras (3/3)

- **Problema**: possibilidade de **underflow**
  - A fórmula do NB para estimar uma classe *c* envolve uma multiplicação de diversos valores de probabilidades.
    - $P(c \mid d) = P(c) \times P(f_1 \mid c) \times P(f_2 \mid c) \times \ldots \times P(f_n \mid c)$
  - Quando muitas variáveis preditivas estão envolvidas no cálculo, pode ocorrer underflow – número muito baixo para ser representado no computador.
- **Solução**: usar a soma dos logaritmos das probabilidades em vez de seus produtos (Jurafsky e Martin, 2026).
    - $\log P(c \mid d) = \log P(c) + \log P(f_1 \mid c) + \log P(f_2 \mid c) + \ldots + \log P(f_n \mid c)\ )$

A Nossa Tabela de Técnicas !!!

- **Tabela: propriedades das técnicas já apresentadas em nosso curso**

Técnica	Principais Aplicações	Dimensão	Paradigma
***n*-Gramas de Caracteres**	*features* para modelos de identif. de plágio, detecção de idioma, atribuição de autor etc.; comparação de strings.	Morfológica	Simbólico
Naïve Bayes Multinomial	análise de sentimentos, classificação de texto em geral	Morfológica	Estatístico

Referências

- JURAFSKY, D.; MARTIN, J. H. Naive Bayes, Text Classification, and Sentiment. *In*: JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing**. 3. ed. (Jan. 6, 2026 draft). [*s.l.*] : [*s.n.*], 2026. Appendix B, p. 1-23. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 24 fev. 2026.

- CHARNIAK, E. Bayesian networks without tears. *In*: **AI Magazine**, v. 12, n. 4, p. 50 – 63, 1991.