Engenharia de Características (*Feature Engineering*)

<u>Aula 09</u>: Introdução ao Processamento de Linguagem Natural (PLN)

Prof. Eduardo Corrêa Gonçalves

30/03/2026

Sumário

Introdução

Engenharia de Características (*Feature Engineering*)

O que é Engenharia de Características ?

Exemplo 1: Eng. de características para análise de sentimentos

Exemplo 2: Eng. de características para classificação de spam

Implementação do Exemplo 1 em Python

Exemplos em papers científicos

Vantagens e Desvantagens

Introdução (1/4)

- **Recordando o NB: Características Principais**
  - As aulas 03 e 04 abordaram o algoritmo **Naïve Bayes Multinomial** (**NB**). Suas principais características são:

    - Serve para **classificação de texto**.
    - **Não é limitado** a problemas binários (com **2 classes**).
    - Atua na **dimensão léxica*** (morfológica)
      - *Ignora sintaxe e semântica*.
    - Tempos de **treinamento** e **classificação** (muito) **rápidos**.

    - **Paradigma Estatístico**.
    - Abordagem **Bayesiana**.
    - **Desempenho aceitável** (bom, ok...) para várias aplicações.
    - Utiliza **Bag of Words** (**BoW**) como *features*.
      - *Também pode utilizar uma Bag de n-Gramas.*

* Na linguística, morfologia e léxico são sistemas diferentes que possuem interseções e interdependência. Detalhes em: https://doi.org/10.9771/2176-4794ell.v2i48.14539. ... *reveja as dimensões da linguagem humana apresentadas na aula 01.*

Introdução (2/4)

- **Conversão texto → dado estruturado**
  - O NB, assim como **todo algoritmo de PLN**, **exige** que o texto (dado não estruturado) seja **convertido** para um vetor numérico (dado estruturado).

comentário	sentimento
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

Introdução (3/4)

- **Conversão texto → dado estruturado**
  - No caso do NB, ele requer que cada **documento** (texto) do corpus (dataset) seja **transformado em uma BoW**.
    - Assim o conjunto de textos se transforma em uma matruz numérica

comentário	sentimento
just plain boring	-
entirely predictable and lacks energy	-
no surprises and very few laughs	-
very powerful	+
the most fun film of the summer	+

	and	boring	energy	entirely	few	film	fun	just	lacks	laughs	most	no	of	plain	powerful	predictable	summer	surprises	the	very
0	0	1	0	0	0	0	0	1	0	0	0	0	0	1	0	0	0	0	0	0
1	1	0	1	1	0	0	0	0	1	0	0	0	0	0	0	1	0	0	0	0
2	1	0	0	0	1	0	0	0	0	1	0	1	0	0	0	0	0	1	0	1
3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	1
4	0	0	0	0	0	1	1	0	0	0	1	0	1	0	0	0	1	0	2	0

Introdução (4/4)

- **Aula de hoje**
  - Hoje avançaremos no tema geração de *features*, abordando o método conhecido como **engenharia de características** (*feature engineering)*
    - É uma outra forma de gerar *features*, diferente da BoW.
    - Tem tudo a ver com Estatística !!!
    - As *features* geradas podem ser usadas pela maioria dos métodos estatísticos e algoritmos de machine learning.
      - *O NB é uma exceção, um dos poucos que só aceita BoW*

Engenharia de Características (1/2)

- **O que é Engenharia de Características** (***Feature Engineering***) **?**
  - É um processo em que cada documento do corpus é **transformado em um conjunto variáveis** (*features*) **previamente definidas** pelos especialistas responsáveis pela criação de um dado classificador.

    - São as variáveis que fazem sentido para aquele problema específico.
    - Normalmente, variáveis interpretáveis.
    - Elas são propostas por especialista(s) no problema que estiver sendo resolvido
      - Análise de sentimentos
      - Detecção de discurso de ódio
      - Detecção de fake news
      - etc.

Engenharia de Características (2/2)

- **Mas <u>como</u> o especialista <u>identifica</u> o conjunto ideal de variáveis ?**
  - Através de um estudo estatístico cuidadoso.
  - Baseado em sua experiência/conhecimento do problema.
  - Consultando a literatura.

Exemplo 1: Classificador de Sentimentos (1/3)

- **Exemplo – Classificador de Sentimentos de *Reviews* de Filmes**
  - Análise de sentimentos é um problema que tem sido estudado há muitos anos.
    - Ao longo do tempo, os especialistas identificaram diversas variáveis relevantes para caracterizar uma opinião como negativa ou positiva.
  - Um exemplo do livro de JURAFSKY e MARTIN (2026) mostra como representar cada documento através de **6 *features***:
    - x_1 = total de palavras positivas no texto
    - x_2 = total de palavras negativas
    - x_3 = 1 se a palavra "*no*" está no texto ou 0 caso contrário
    - x_4 = total de pronomes (1ª e 2ª pessoa)
    - x_5 = 1 se "!" está no texto ou 0 caso contrário
    - x_6 = *log*(total de palavras do texto)

Exemplo 1: Classificador de Sentimentos (2/4)

- **Exemplo – Extraindo as features de um texto** (JURAFSKY e MARTIN, 2026)
  - Dado o texto abaixo, veja como são extraídas as 6 *features* propostas:

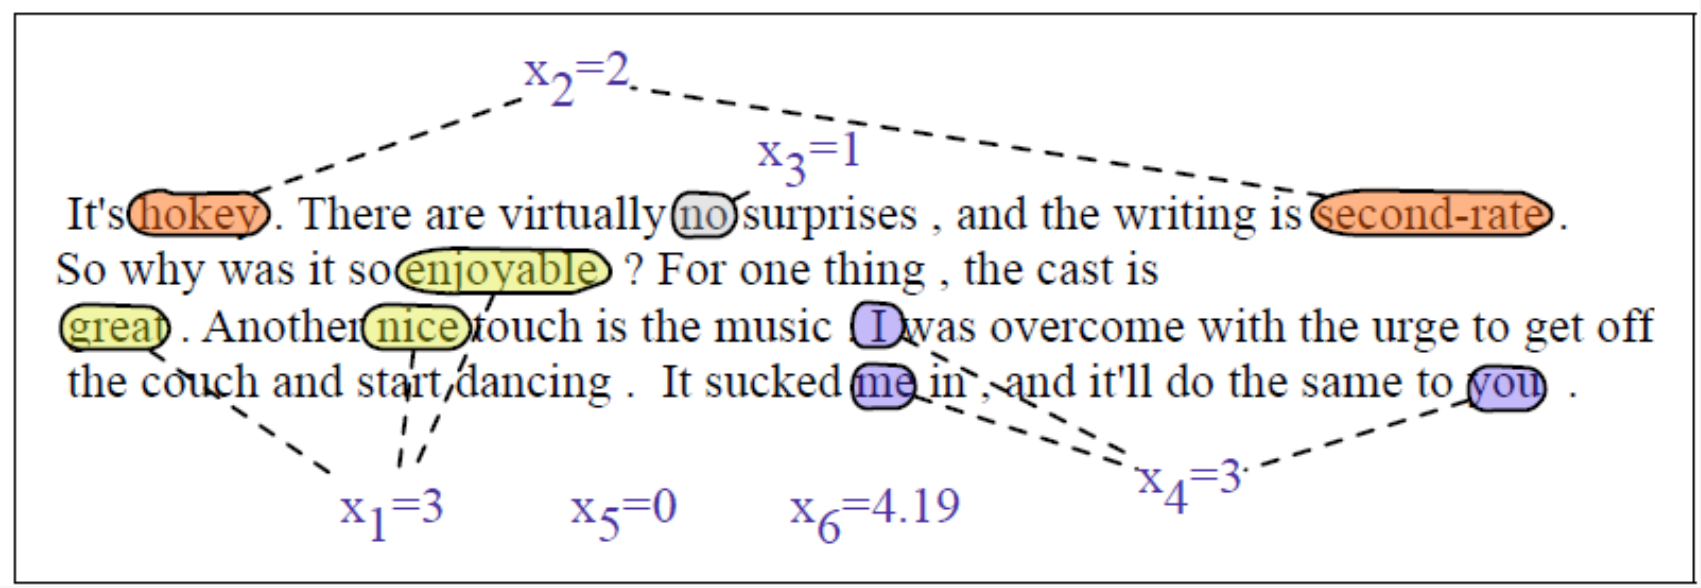

- x_1 = total de palavras positivas no texto
- x_2 = total de palavras negativas
- x_3 = 1 se a palavra "no" está no texto ou 0 caso contrário
- x_4 = total de pronomes (1ª e 2ª pessoa)
- x_5 = 1 se "!" está no texto ou 0 caso contrário
- x_6 = *log*(total de palavras do texto)

x = [3, 2, 1, 3, 0, 4.19]

Como sempre, o texto bruto foi estruturado, i.e., virou um vetor numérico!

Exemplo 1: Classificador de Sentimentos (3/3)

- **Meta-variáveis**
  - Na literatura, as *features* geradas através da engenharia de características são comumente chamadas de **meta-variáveis**.
    - Em inglês *meta-level features* ou *meta-features*
    - *handcrafted features* também é muito usado, para caracterizar que se trata de um processo "artesanal".

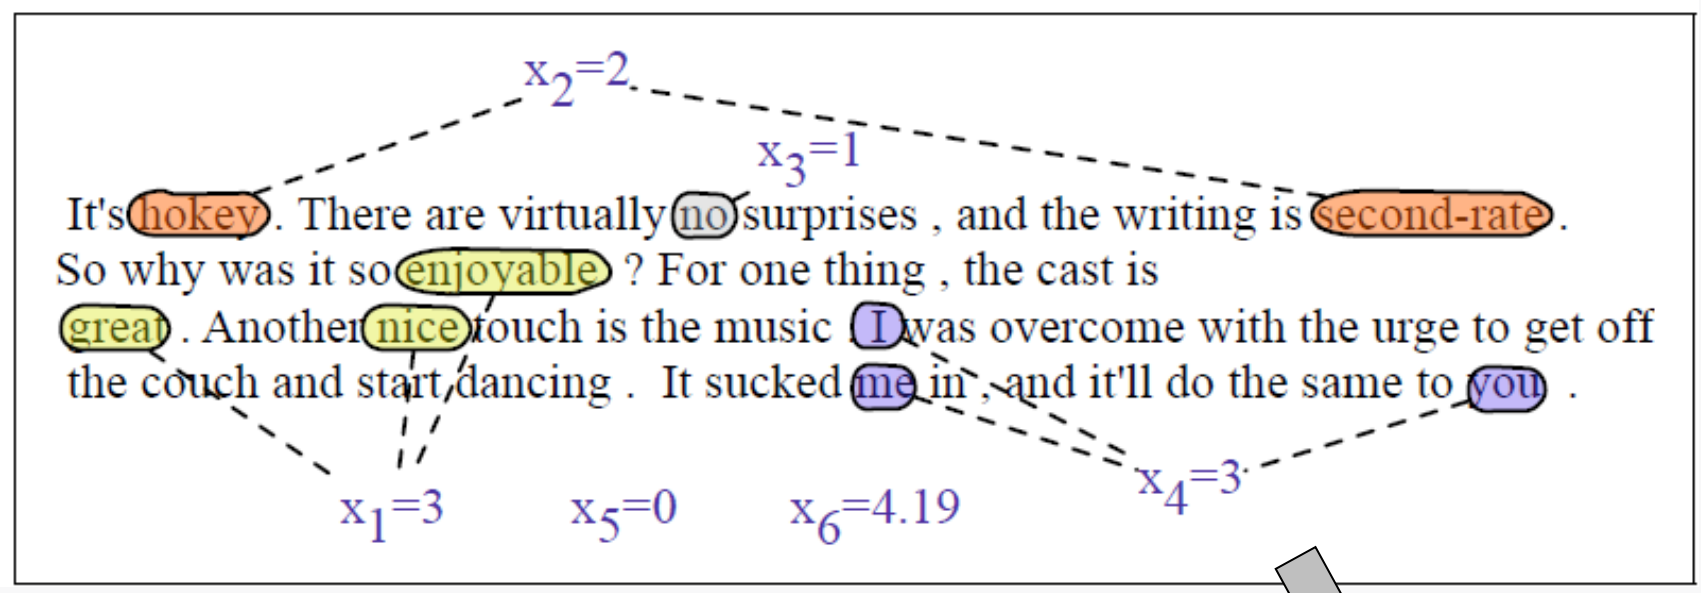

x = [3, 2, 1, 3, 0, 4.19]

Exemplo 2: Classificador de Spam

- **Exemplo 2 – Classificador de Spam**

	spam	num_char	line_breaks	format	number
1	no	21,705	551	html	small
2	no	7,011	183	html	big
3	yes	631	28	text	none
⋮	⋮	⋮	⋮	⋮	⋮
50	no	15,829	242	html	small

Table 1.3: Four rows from the email50 data matrix.

- **num_char** (inteiro): número de caracteres no e-mail.
- **line_breaks** (inteiro): número de quebra de linhas no e-mail.
- **format** (categórico): indica se o e-mail contém comandos de formatação HTML.
- **number** (ordinal): indica se o e-mail não contém nenhum número, se contém um número pequeno ou um número grande.

- **Fonte:** https://www.openintro.org/book/os/. É apenas um exemplo conceitual, na prática muitas outras variáveis são utilizadas.

Engenharia de Características no Python (1/7)

- **Exemplo: Base de dados (BD)**: "sentiment140"
- **Meta-variáveis**:
  - x_1 = total de palavras positivas no texto
  - x_2 = total de palavras negativas
  - x_3 = 1 se a palavra "*no*" está no texto ou 0 caso contrário
  - x_4 = total de pronomes (1ª e 2ª pessoa)
  - x_5 = 1 se "!" está no texto ou 0 caso contrário
  - x_6 = *log*(total de palavras do texto)

- Supondo que já existe um DataFrame "X_raw" com os tokens de cada documento, como gerar as 6 meta-variáveis acima?

	review	tokens
0	@stellargirl I loooooooovvvvvveee my Kindle2. ...	[@, stellargirl, i, loooooooovvvvvveee, my, ki...
1	Reading my kindle2... Love it... Lee childs i...	[reading, my, kindle2, ..., love, it, ..., lee...
2	Ok, first assesment of the #kindle2 ...it fuck...	[ok, ,, first, assesment, of, the, #, kindle2,...
3	@kenburbary You'll love your Kindle2. I've had...	[@, kenburbary, you, 'll, love, your, kindle2,...
4	@mikefish Fair enough. But i have the Kindle2...	[@, mikefish, fair, enough, ., but, i, have, t...
...	...	...
354	After using LaTeX a lot, any other typeset mat...	[after, using, latex, a, lot, ,, any, other, t...
355	On that note, I hate Word. I hate Pages. I hat...	[on, that, note, ,, i, hate, word, ., i, hate,...
356	Ahhh... back in a *real* text editing environm...	[ahhh, ..., back, in, a, *, real, *, text, edi...
357	Trouble in Iran, I see. Hmm. Iran. Iran so far...	[trouble, in, iran, ,, i, see, ., hmm, ., iran...
358	Reading the tweets coming out of Iran... The w...	[reading, the, tweets, coming, out, of, iran, ...

359 rows × 2 columns

Engenharia de Características no Python (2/7)

- **Exemplo: Base de dados (BD)**: "sentiment140"
- **Meta-variáveis**:
  - **x_1 = total de palavras positivas no texto**
  - **x_2 = total de palavras negativas**
  - x_3 = 1 se a palavra "*no*" está no texto ou 0 caso contrário
  - **x_4 = total de pronomes (1ª e 2ª pessoa)**
  - x_5 = 1 se "!" está no texto ou 0 caso contrário
  - x_6 = *log*(total de palavras do texto)

- Para criar as variáveis x_1, x_2 e x_4 precisamos passar para o programa uma lista contendo palavras positivas, uma lista com palavras negativas e uma lista com pronomes respectivamente.

  - É fácil encontrar na Internet... Vou usar os léxicos de Hu & Liu (2004) → http://www.cs.uic.edu/~liub/FBS/sentiment-analysis.html

Engenharia de Características no Python (3/7)

- **Léxicos Utilizados**

```
1    a+
2    abound
3    abounds
4    abundance
5    abundant
6    accessable
7    accessible
8    acclaim
9    acclaimed
10   acclamation
11   accolade
12   accolades
13   accommodative
14   accomodative
15   accomplish
```

Trecho do léxico de palavras **positivas**

```
1    2-faced
2    2-faces
3    abnormal
4    abolish
5    abominable
6    abominably
7    abominate
8    abomination
9    abort
10   aborted
11   aborts
12   abrade
13   abrasive
14   abrupt
15   abruptly
```

Trecho do léxico de palavras **negativas**

Lista com **pronomes** na 1ª e 2ª pessoas

```
['i', 'me', 'my', 'mine', 'myself',
 'we', 'us', 'our', 'ours',
 'ourselves', 'you', 'your', 'yours',
 'yourself', 'yourselves']
```

Engenharia de Características no Python (4/7)

- **Código (Parte 1)**
  - O trecho de código a seguir:
    - importa os léxicos de palavras positivas (pos.txt) e negativas (neg.txt) para uma lista.
    - E define a lista de pronomes na 1ª pessoa e 2ª pessoa

```
# lê o dicionário de palavras positivas e o converte p/ 1 lista
pos =
pd.read_csv("https://raw.githubusercontent.com/edubd/bd/refs/he
ads/main/pos.txt",header=None, names = ['palavra’])

pos = pos['palavra'].to_list()

# lê o dicionário de palavras negativas e o converte p/ 1 lista
neg =
pd.read_csv("https://raw.githubusercontent.com/edubd/bd/refs/he
ads/main/neg.txt",header=None, names = ['palavra’])

neg = neg['palavra'].to_list()

# define o dicionário de palavras na 1a e 2a pessoas
pronomes = ['i', 'me', 'my', 'mine', 'myself', 'we', 'us',
'our', 'ours', 'ourselves', 'you', 'your', 'yours', 'yourself',
'yourselves']
```

Engenharia de Características no Python (5/7)

- **<u>Código</u> (Parte 2)**
  - Agora cria-se uma função para cada *feature*.
    - Novas colunas x_1 a x_6 serão criadas no DataFrame aplicando sua respectiva função sobre a coluna com os tokens.
    - Os próximos slides exibem o código

Engenharia de Características no Python (6/7)

- **Código (Parte 2)**

```
# Define as funções para gerar as features numéricas
import math

def f_gera_x1(tokens):
  # quantidade de palavras positivas
  return sum([1 if token in pos else 0 for token in tokens])

def f_gera_x2(tokens):
  # quantidade de palavras negativas
  return sum([1 if token in neg else 0 for token in tokens])

def f_gera_x3(tokens):
  # palavra "no" ou "not" está no texto
  if 'no' in tokens or 'not' in tokens: return 1
  else: return 0

def f_gera_x4(tokens):
  # quantidade de pronomes na 1a ou 2a pessoa
  return sum([1 for token in tokens if token in pronomes])

def f_gera_x5(tokens):
  # palavra "!" está no texto
  return 1 if '!' in tokens else 0

def f_gera_x6(tokens):
  # log do total de palavras do texto
  return math.log(len([token for token in tokens if token.isalnum()]))
```

IBGE
Escola Nacional de Ciências Estatísticas ENCE

Engenharia de Características no Python (7/7)

- **<u>Código</u> (Parte 2)**

```
# (4) aplica as funções
X = X_raw.copy()
X['x1'] = X['tokens'].apply(f_gera_x1)
X['x2'] = X['tokens'].apply(f_gera_x2)
X['x3'] = X['tokens'].apply(f_gera_x3)
X['x4'] = X['tokens'].apply(f_gera_x4)
X['x5'] = X['tokens'].apply(f_gera_x5)
X['x6'] = X['tokens'].apply(f_gera_x6)
```

Resultado final (X pré-processado)

	review	x1	x2	x3	x4	x5	x6
0	@stellargirl I loooooooovvvvvveee my Kindle2. ...	3	0	1	2	0	2.995732
1	Reading my kindle2... Love it... Lee childs i...	2	0	0	1	0	2.302585
2	Ok, first assesment of the #kindle2 ...it fuck...	0	1	0	0	1	2.197225
3	@kenburbary You'll love your Kindle2. I've had...	1	1	1	4	1	3.258097
4	@mikefish Fair enough. But i have the Kindle2...	3	0	0	2	0	2.564949

IBGE
Escola Nacional de Ciências Estatísticas ENCE

Exemplos em artigos científicos (1/5)

- **<u>Exemplo 1</u>: Análise de Sentimentos** (Carvalho e Plastino, 2021)
  - Realizou a avaliação empírica de um conjunto de **120 meta-variáveis** propostas na literatura para análise de sentimentos
  - Cenário de teste:
    - 22 datasets de análise de sentimentos.
    - Algoritmos: SVM, Random Forest e Regressão Logística

Exemplos em artigos científicos (2/5)

- **<u>Exemplo 1 (cont.)</u>: Análise de Sentimentos** (Carvalho e Plastino, 2021)

Table 3 Overview of the meta-level features proposed in the literature of Twitter sentiment classification

Category	Features
Microblog (*10 features*)	*Wheter the tweet has*: retweet, hashtag, user mention, URL, repeated letters, abbreviation, internet slang
	Number of: repeated letters, abbreviation, internet slang
Part-of-Speech (*25 features*)	*Number of*: common noun, proper noun, personal pronoun, common noun + possessive, common noun + verb, proper noun + possessive, proper noun + verb, verb, adjective, adverb, interjection, punctuation, determiner, pre or post-position, conjunction, verb particle, predeterminer, predeterminer + verb, hashtag, user mention, discourse marker ("RT" and ":" in retweet), URL or email address, numeral, symbol
Surface (*15 features*)	*Whether the tweet has*: question mark, exclamation mark
	Whether last token contains: question mark, exclamation mark
	Number of: words, capitalized words, words with all letters capitalized, capital letters, punctuation, question mark, exclamation mark, sequence of question marks, sequence of exclamation marks, sequence of both question and exclamation marks
	Average of: char length of words
Emoticon (*10 features*)	*Wheter the tweet has*: emoticon, positive emoticon, negative emoticon
	Whether the last token is: positive emoticon, negative emoticon
	Number of: emoticons, positive emoticons, negative emoticons, extremely positive emoticons, extremely negative emoticons
Lexicon-based (*70 features*)	*Number of*: positive adjective, negative adjective, positive noun, negative noun, positive adverb, negative adverb, positive verb, negative verb, negated contexts, negation words, intensifier words, counter factuality words, temporal compression words
	Sum of the scores of the adjectives, adverbs, verbs, and nouns
	For each sentiment lexicon (AFINN Nielsen 2011, Bing Liu's lexicon Liu 2012, NRC-emotion Mohammad and Turney 2013, NRC-hashtag Mohammad et al. 2013, OpinionFinder Wilson et al. 2005 Sentiment140 lexicon Mohammad et al. 2013, and SentiWordNet Baccianella et al. 2010):
	– *Number of*: positive words, negative words
	– *Total score of*: positive words, negative words
	– *Maximal score of*: positive words, negative words
	– *Balance score of the tweet*
	– *Score of the last token*

Exemplos em artigos científicos (3/5)

- **<u>Exemplo 2</u>: Classificação de Persuasão** (de Azevedo e Gonçalves, 2026)
  - Realizou a avaliação empírica de um conjunto de **46 meta-variáveis** em um problema de classificação de persuasão em textos de memes.
  - Cenário de teste:
    - 1 dataset com textos de memes (Dimitrov et al. 2024).
    - Algoritmos: Random Forest e Regressão Logística

Figura 1. Um exemplo de meme persuasivo da base de dados de treinamento

Exemplos em artigos científicos (4/5)

- **<u>Exemplo 2 (cont.)</u>: Classificação de Persuasão** (de Azevedo e Gonçalves, 2026)
  - Dentre as meta-variáveis avaliadas, o grupo que mais se destacou foi o das meta-variáveis relacionadas à **Retórica Aristotélica**
    - Apelo para emoção (*pathos*);
    - Apelo para ética (*ethos*);
    - Apelo para lógica (*logos*).

Pathos

- Frases emotivas: frequência de lemas positivos e negativos (gerais, substantivos e adjetivos), com base no léxico de sentimentos de Hu and Liu [2004].
- Uso da voz passiva: avaliação binária da presença de sujeitos passivos (etiqueta *nsubjpass*) em verbos no particípio (*VBN*) com verbos auxiliares como dependentes.
- Sentimento: escores positivos, neutros, negativos e compostos obtidos via análise da abordagem VADER [Hutto and Gilbert, 2015].

Ethos

- Uso de pronomes: detecção de frases cujo sujeito seja um pronome, a partir das etiquetas *nsubj* e *PRP*.
- Tempo verbal futuro: presença de estruturas com sujeito (*nsubj*), verbo principal e verbo auxiliar futuro como filhos do mesmo núcleo verbal.
- Personalismo: avaliação binária da presença de advérbios e conjunções subordinativas, como marcadores de subjetividade.

Logos

- Dados numérico-nominais: detecção de tokens com etiqueta *CD* (número cardinal) seguidos diretamente por tokens nominais (*NN*, *NNS* etc.), assim como citações a pessoas e organizações.
- Frases complexas e longas: presença de orações compostas, com estruturas sintáticas envolvendo sujeito, verbo, adjuntos adverbiais e conectores subordinativos ou coordenativos, identificadas via *DependencyParser*.
- Formalidade: caracterizada pelo uso de voz passiva, construção em terceira pessoa e frases declarativas.

Exemplos em artigos científicos (5/5)

- **Exemplo 2 (cont.): Classificação de Persuasão** (de Azevedo e Gonçalves, 2026)
  - Um exemplo de extração de meta-variáveis a partir de um texto da base

3.5 Exemplo de Extração de Meta-Variáveis

A seguir, apresenta-se um exemplo que ilustra como são obtidos os valores das metas-variáveis a partir do texto original de um meme. O exemplo em questão utiliza o texto de um meme persuasivo da base de dados de treino e mostra algumas das meta-variáveis que foram extraídas a partir dele.

CROOKS & LIARS AS PRESIDENTS? WASN'T ONE CLINTON ENOUGH?[4]

- **total_neg_nn (Grupo 2, Sentimento):** O valor é **2**, contabilizado após a verificação dos lemmas dos substantivos "CROOKS" e "LIARS" estarem presentes no léxico de palavras negativas de Hu and Liu [2004].
- **subjecitivity (Grupo 1, Ethos):** O valor é **1**, indicando uso de linguagem subjetiva pelo advérbio "ENOUGH".
- **numerical_nominal (Grupo 1, Logos):** O valor é **1**, sinalizado pela combinação do número cardinal "ONE" seguido do substantivo pessoal "CLINTON".
- **person_named (Grupo 1, Logos):** O valor é **1**, extraído da entidade nomeada "CLINTON" (sobrenome reconhecido de um chefe de Estado).

Prós e Contras (1/2)

- **Engenharia de Características – Pontos positivos**
  - ☺ **Relação com a estatística** – as variáveis são definidas de uma forma bastante relacionada com o que é tradicionalmente feito na estatística.
    - Através de estudo sobre os dados ou da experiência/conhecimento de especialistas.
  - ☺ **Interpretabilidade** – As meta variáveis costumam ser interpretáveis.
    - Ótimas quando desejamos descobrir a ligação entre evidências e resultados utilizando métodos como Regressão Logística, por exemplo
      - (*podemos realizar a análise das variáveis que estão positivamente e negativamente associadas a uma classe*).
  - ☺ **Vai além da dimensão morfológica** – Consegue capturar algumas informações sintáticas e semânticas (embora de forma limitada).
  - ☺ **Flexibilidade** – Serve para a esmagadora maioria dos algoritmos
    - Os textos viram vetores numéricos que podem ser utilizados por algoritmos como Perceptron, Regressão Logística, k-Médias, Floresta Aleatória, Regressão Linear etc. (o NB é um dos poucos que não suporta...).

Prós e Contras (2/2)

- **Engenharia de Características – Pontos negativos**
  - ☹ **Não é o método mais eficaz** – Os métodos neurais modernos geram automaticamente *features* que costumam produzir modelos com melhor desempenho.
    - Essas features são chamadas de embeddings e serão apresentadas em aulas futuras.
  - ☹ **Processo trabalhoso** – O processo de extração de meta-variáveis é artesanal
    - Por isso, costuma exigir um esforço razoável de programação.
    - Além disso, cada problema tem o seu conjunto de meta-variáveis adequado. Por exemplo, as variáveis para análise de sentimentos não são as mesmas usadas para classificação de spam.
  - ☹ **Tratamento semântico muito básico** – captura aspectos semânticos (ex.: total de palavras negativas e positivas), mas de forma limitada.
    - Por exemplo, não captura o contexto, um aspecto muito relevante.

A Nossa Tabela de Técnicas !!!

- **Tabela: propriedades das técnicas apresentadas em nosso curso**

Técnica	Principais Aplicações	Dimensão	Paradigma
***n*-Gramas de Caracteres**	*features* para modelos de identif. de plágio, detecção de idioma, atribuição de autor etc.; comparação de strings.	Morfológica	Simbólico
Bag of Words (BoW)	produzir *features* p/ Naive Bayes e algoritmos de classificação, *clustering*, regressão etc.	Morfológica	Simbólico
Naïve Bayes Multinomial	análise de sentimentos, classificação de texto	Morfológica	Estatístico
Perceptron	classificação binária de texto	Fonética a Semântica	Estatístico, Neural
Engenharia de características	produzir *features* para algoritmos de classificação, *clustering*, regressão etc.	Fonética a Semântica	Simbólico, Estatístico

Referências

- DE AZEVEDO, A. B. S.; GONÇALVES, E. C. Explorando meta-variáveis para a classificação de persuasão em textos de memes políticos. **Revista Eletrônica de Iniciação Científica em Computação**, v. 24, n. 1, p. 1–9, 2026.

- CARVALHO, J.; PLASTINO, A. On the evaluation and combination of state-of-the-art features in Twitter sentiment analysis. **Artificial Intelligence Review**, v. 54, p. 1887–1936, 2021.

- DIMITROV, D. et al. SemEval-2024 task 4: Multilingual detection of persuasion techniques. *In*: Proc. of the 18th International Workshop on Semantic Evaluation (SemEval-2024), 2024, Mexico City. **Anais** […] [*s.l.*]: ACL, 2024.

- JURAFSKY, D.; MARTIN, J. H. Logistic Regression. *In*: JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing**. 3. ed. *draft* [*s.l.*] : [*s.n.*], 2026. cap 4, p. 6-8. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 10 mar. 2026.