

Wordnets

Aula 13: Introdução ao Processamento de Linguagem Natural (PLN)

Prof. Eduardo Corrêa Gonçalves

25/05/2026

Sumário

Introdução

O que é Wordnet ?

Wordnet *versus* Embeddings

Wordnets – detalhando um pouco mais

A WordNet original

Synsets (nós) e relações semânticas (arestas)

Detalhando um synset


Wordnets na prática

Caso: Similaridade semântica de nomes de marcas

Exemplos em Python


Introdução (1/4)

- O que é Wordnet?
- É um **repositório organizado** de **itens lexicais** (palavras ou expressões) de um determinado idioma (Inglês, Português, Espanhol etc.).
- Os itens lexicais são organizados em **synsets** (que vem de *synonym sets* – conjuntos de palavras sinônimas)



Introdução (2/4)

- Uma Wordnet é uma estrutura capaz de:
 - Representar os diferentes **significados das palavras** (*word senses*).
 - E as **relações** entre essas palavras: sinônimos, hiperônimos, antônimos etc.
 - No exemplo abaixo, estão representados os **sinônimos** e as relações **hiperônimo** → **hipônimo**.



Introdução (3/4)

- **Wordnet: a “rainha” da semântica simbólica**
 - A wordnet é um recurso (uma **fonte de conhecimento**) utilizado por aplicações que trabalham com **semântica**.
 - Certamente, o recurso mais sofisticado e, talvez, o mais conhecido e utilizado na **semântica simbólica**.
 - Relembrando que:
 - Métodos simbólicos envolvem a utilização de **regras** e **representações formais explícitas** para processar e entender textos em linguagem natural (SENO et al. 2024).

Introdução (4/4)

- **Wordnets *versus* Embeddings**
 - As wordnets já existiam antes dos embeddings e já eram usadas em muitas aplicações.
 - As wordnets e os embeddings atuam no nível **semântico**.
 - As **wordnets** se baseiam em teorias **psicolinguísticas** (*próximo slide*)
 - Já os embeddings se baseiam na **semântica distribucional**,
 - Hoje em dia, **embeddings** baseados em *deep learning* como o BERT são **mais populares**, pois se demonstraram mais efetivos. Porém, é importante ressaltar que:
 - **Embeddings nem sempre podem ser utilizados** em aplicações que exijam a **interpretação** das razões pelas quais um modelo chegou a uma decisão.
 - **Exemplo:** aplicações na Medicina e Administração Pública.

Wordnets (1/5)

- **História da WordNet**

- A WordNet original (para língua inglesa) foi desenvolvida por uma equipe de pesquisadores da Universidade de Princeton.
- “*Construída com base em teorias psicolinguísticas que modelam as organização semântica das pessoas*”
- Gratuita, largamente utilizada, muito abrangente (começou a ser construída ainda na década de 1980 e é atualizada periodicamente).
- Wordnet 3.0: 155.287 synsets
 - **Substantivos** (total = 117.798)
 - **Verbos** (total = 11.529)
 - **Adjetivos e Advérbios** (totais = 21.479 e 4.481, respectivamente).
- Atualmente, existem Wordnets para diversos idiomas, incluindo Português (OLIVEIRA et al. 2015). Porém, normalmente não são tão abrangentes ou acuradas quanto a WordNet original.


Wordnets (2/5)

- Estrutura da Wordnet

- Uma Wordnet de um dado idioma é um **enorme e complexo grafo**.

- Os **nós** do grafo são os **synsets** (conjuntos de sinônimos).

- E as **arestas** as **relações** entre os synsets (hiperonímia, antonímia, etc.).



Fonte: Jurafsky e Martin (2015)

Wordnets (3/5)

- **Estrutura de uma Wordnet (cont...)**
 - Cada synset (nó do grafo) armazena um conjunto de termos (**lemas**) sinônimos em determinado contexto.
 - Também armazena a **classe gramatical** (**part-of-speech – PoS**): substantivo, verbo, adjetivo etc.
 - Uma **definição** (**gloss**)
 - Abaixo, 2 synsets que possuem o lema “**banco**”, ambos substantivos (PoS = sub)

043916 (sub) | {**tamborete, cadeira, banquinho, banco, banqueta**}
(*um assento simples sem braços ou encosto*)

084217 (sub) | {**banco, instituição financeira, instituição bancária**}
(*estabelecimento de crédito, que tem por objetivo receber depósitos, aplicar capital, realizar empréstimos etc.*)

Wordnets (4/5)

- As Wordnets são usadas, entre outras aplicações, para:
 - Medir a **similaridade** entre palavras, frases ou textos.
 - *É o exemplo que apresentaremos nessa aula*
 - **Sistemas de tradução**
 - O Google Tradutor utiliza a OpenWordnet-PT para fazer traduções para o Português.
 - **Sistemas PR** e chatbots
 - Saber que “cartola” além de ser um “tipo de chapéu” também é um “tipo de doce” é certamente útil na resposta de questões de pessoas que querem aprender a preparar esse doce.



Wordnets (5/5)

- À seguir...
 - Primeiro vamos apresentar uma aplicação prática (real e bem sucedida) da WordNet em Inglês.
 - Depois, no notebook da aula, vamos apresentar exemplos de utilização da OpenWordnet-PT (Português) através da NLTK do Python.
 - Os interessados em conhecer mais detalhes teóricos sobre wordnets poderão consultar as seguintes referências: Jurafsky e Martin (2025), Anuar et al. (2016), Seno et al. (2024).

Caso: Similaridade de Nomes de Marcas (1/15)

- Aplicação – STS de nomes de marcas (Anuar et al., 2016)
 - Objetivo: resolver um problema real de propriedade intelectual no Reino Unido.
 - Proposta de um método para avaliar a **similaridade conceitual** entre **nomes de marcas** (*trademarks*).
 - A similaridade conceitual ocorre quando dois nomes de marcas evocam **conteúdo semântico idêntico ou análogo** podendo levar o consumidor a se confundir.

NOME DE MARCA 1

FEEL 'N LEARN

NOME DE MARCA 2

SEE 'N LEARN

- É um tipo de aplicação STS – *semantic textual similarity*

Caso: Similaridade de Nomes de Marcas (2/15)

- **Motivação**
 - **Nomes de marcas** são importantes **ativos de propriedade intelectual** das empresas.
 - Nomes similares podem levar o consumidor a se **confundir**.
 - Ele pensa que está comprando o produto A, quando na verdade está comprando o produto B.
 - Milhares de casos de **violação de trademarks** são julgados por ano.

The trademarks "FEEL 'N LEARN" and "SEE 'N LEARN" also ultimately suggest very similar meanings. The fact that the verbs "FEEL" and "SEE" by themselves denote different sensory perceptions does not change the fact that both trademarks contain the idea of learning with the aid of sensory organs. This fundamental idea remains in the mind of the consumer, which is why trademark similarity is also affirmed from a semantic point of view (this was also the decision of the RKGE on 21 December 2001, 3/20002172 E. 6. S. 172 – Fly away / Float away).

Caso: Similaridade de Nomes de Marcas (3/15)


- **Sistemas de Comparação de Trademarks – Situação em 2016**
 - ENTRADA: Usuário digita um nome de marca
 - SAÍDA: trademarks mais similares de acordo com:
 - Casamento exato → Pizza at Home x Pizza at Home
 - Casamento de prefixo → Pizza at Home x Pizza at Night
 - Casamento aproximado → Pizza at Home x Pizza@Home
 - **Vantagem**: não precisam usar fonte de conhecimento externo
 - **Desvantagem**: não consideram a similaridade conceitual, que deve ser examinada com base no conteúdo semântico das trademarks.
 - “FEEL ‘N LEARN” *versus* “SEE ‘N LEARN”
 - O sistema não sabe que “FEEL” e “SEE” são semanticamente parecidos.
 - Ambos envolvem a ideia de aprender através dos sentidos.

Caso: Similaridade de Nomes de Marcas (4/15)

- **Resumo do Método Proposto em Anuar et al. (2016):**
 - Baseado em **similaridade semântica**
 - Não se baseia na similaridade de caracteres (casamento exato, aproximado ou de prefixo)
 - Emprega uma **Ontologia Lexical**
 - Base de dados de palavras, seus significados e relações com outras palavras (*espécie de dicionário “sofisticado”*).
 - A ontologia lexical usada no trabalho é exatamente a **WordNet** da língua Inglesa
- Obteve **efetividade de 13% a 20% superior** a dos sistemas utilizados na ocasião em testes realizados com duas bases de dados de nomes de marcas em Inglês.
 - Não houve comparação com embeddings. Porém, é sabido que na prática os embeddings nem sempre são bons para comparar nomes curtos (sofrem com a falta de contexto nesse caso)

Caso: Similaridade de Nomes de Marcas (5/15)

- O trabalho fez uso apenas das seguintes relações semânticas:
- Sinônimo, Hiperônimo e Hipônimo



Caso: Similaridade de Nomes de Marcas (6/15)

- **Propõe medida de similaridade com 3 partes:**
 - PARTE 1: baseada na proporção de termos em comum
 - PARTE 2: baseada na proporção de sinônimos, hiperônimos e hipônimos de Q que são comuns a T
 - PARTE 3: baseada na topologia grafo. Testou 6 abordagens diferentes
- **Exemplo:**
 - “cassava and peas” x “beans and manioc”
 - **Qual a similaridade entre esses nomes?**

Caso: Similaridade de Nomes de Marcas (7/15)

- **Passo Preliminar:**
 - Transforma os nomes em conjuntos de termos
 - “cassava and peas” $\rightarrow Q = \{\text{“cassava”, “pea”}\}$
 - “beans and manioc” $\rightarrow T = \{\text{“bean”, “manioc”}\}$
 - Obtém **R**, o conjunto de sinônimos, hiperônimos e hipônimos de Q
 - **R** = {“manioc”, “root vegetable”, “legume”}
 - Obtivemos R usando a ontologia do slide 16:
 - “manioc” é sinônimo de “cassava”
 - “root vegetable” é hiperônimo de “cassava”
 - “legume” é hiperônimo de “pea”


Caso: Similaridade de Nomes de Marcas (8/15)

- Agora que temos os 3 conjuntos a similaridade pode ser calculada:
 - $Q = \text{"cassava and peas"} \rightarrow \{\text{"cassava"}, \text{"pea"}\}$
 - $T = \text{"beans and manioc"} \rightarrow \{\text{"bean"}, \text{"manioc"}\}$
 - $R = \{\text{"manioc"}, \text{"root vegetable"}, \text{"legume"}\}$
- PARTE 1:
 - $|Q \cap T| / |Q \cup T| = 0 / 4 = 0.00$
- PARTE 2:
 - $|R \cap T| / \max(|T|, |Q|) = 1 / 2 = 0.50$
- PARTE 3:
 - É um pouco mais complicada, baseia-se na distância entre os termos na WordNet.
 - Testou 6 medidas, entre elas **Wu & Palmer**

Caso: Similaridade de Nomes de Marcas (9/15)

- Similaridade – Medida de Wu & Palmer (WP)

- Para WP, a similaridade é função do **caminho** que liga dois termos.
- Devemos levar em conta o quanto estão **próximos**...
- ... e a **profundidade** (*depth*) dos termos na ontologia.
- Intuição**: synsets **próximos na parte mais profunda** são **mais similares** do que os que estão próximos na parte superior.



Caso: Similaridade de Nomes de Marcas (10/15)


- Similaridade – Medida de Wu & Palmer (WP)

$$WP = 2 \times d3 / (d1 + d2 + 2 \times d3)$$

- $d1$ = distância do termo 1 ao ancestral em comum
- $d2$ = distância do termo 2 ao ancestral em comum
- $d3$ = distância da raiz ao ancestral em comum
- A distância é dada pelo **número de arestas** entre os nós.

$\text{sim}(\text{"Laranja Lima"}, \text{"Laranja Seleta"}) =$

$$(2 \times 3) \div (1 + 1 + 2 \times 3) = 0,75$$



Caso: Similaridade de Nomes de Marcas (11/15)


- Medida de Wu & Palmer

$$WP = 2 \times d3 / (d1 + d2 + 2 \times d3)$$

$$\text{sim}(\text{"Laranja Lima"}, \text{"Laranja Seleta"}) = \\ (2 \times 3) \div (1 + 1 + 2 \times 3) = \mathbf{0,75}$$


$$\text{sim}(\text{"Laranja"}, \text{"Maçã"}) = \\ (2 \times 2) \div (1 + 1 + 2 \times 2) = \mathbf{0,67}$$

$$\text{sim}(\text{"Alimentação"}, \text{"Lazer"}) = \\ (2 \times 0) \div (1 + 1 + 0) = \mathbf{0,0}$$



Caso: Similaridade de Nomes de Marcas (12/15)

- Medida de Wu & Palmer (WP)
- Nos **embeddings** medimos a similaridade com o **cosseno** dos vetores.
- Nas **wordnets**, medimos com **Wu & Palmer** e outras medidas.
 - WP é a mais conhecida.
 - Mas há **muitas outras medidas de similaridade** para wordnets.
 - Tanto WP como o cosseno retornam um valor entre 0.0 (totalm. dissimilares) e 1.0 (equivalentes)



Caso: Similaridade de Nomes de Marcas (13/15)


- Retornando para o nosso exemplo:
 - $Q = \{\text{"cassava"}, \text{"pea"}\}$
 - $T = \{\text{"bean"}, \text{"manioc"}\}$
 - $R = \{\text{"manioc"}, \text{"root vegetable"}, \text{"legume"}\}$
- PARTE 1: $|Q \cap T| / |Q \cup T| = 0 / 4 = \underline{0.00}$
- PARTE 2: $|R \cap T| / \max(|T|, |Q|) = 1 / 2 = \underline{0.50}$
- PARTE 3: Na parte 3 ele faz a média dos “melhores” valores de similaridade de WP entre todos os termos de Q e todos os de T (exceto termos iguais).
 - $\text{Max}[WP(\text{"cassava"}, \text{"bean"}), WP(\text{"cassava"}, \text{"manioc"})] = 1.00$
 - $\text{Max}[WP(\text{"pea"}, \text{"bean"}), WP(\text{"pea"}, \text{"manioc"})] = 0.50$
 - $\text{Média WP} = (1.00 + 0.50) / 2 = \underline{0.75}$
- Valor de **similaridade final** = $0.00 + 0.50 + 0.75 = \underline{1.25}$

Caso: Similaridade de Nomes de Marcas (14/15)

- Uma pequena observação...
 - P1: 0.00
 - P2: 0.50
 - P3: 0.75
 - Valor de **similaridade final** = $0.00 + 0.50 + 0.75 = \underline{1.25}$
- Em geral, o valor de similaridade deveria estar na faixa entre 0.00 (totalmente dissimilares) e 1.00 (totalmente similares).
- O método proposto retorna um valor entre 0.00 e 3.00
 - Bastava ele somar ($P1 + P2 + P3$) e dividir por 3 ...

Caso: Similaridade de Nomes de Marcas (15/15)

- **Resultados - Fez 2 experimentos.**
 - **Análise Objetiva** → acurácia de Levenshtein *versus* do Método Proposto
 - *Base de dados com 56 pares de trademarks*
 - *Testou 6 diferentes medidas na Parte 3 da fórmula*



- **Análise Subjetiva** → Opinião de especialistas
 - Especialistas observaram os casamentos para ver se foram corretos

Wordnet – prós e contras

- **Vantagens:**

- (1) Estrutura criada cuidadosamente por especialistas
- (2) Permite com que aplicações façam inferências interpretáveis (é sempre possível entender o motivo de uma classificação, decisão etc.).
- (3) A WordNet de Princeton (original) é muito abrangente.
- (4) Uso básico através da NLTK é simples.

- **Desvantagens:**

- (1) Uma wordnet é um grafo. Então o uso avançado não é trivial, pois requer que seja escrito código para caminhar pelas arestas do grafo.
- (2) Infelizmente as wordnets do Português não são tão completas ou acuradas como a Wordnet de Princeton (o notebook da aula exemplifica isso).

A Nossa Tabela de Técnicas !!!

- Tabela: propriedades das técnicas apresentadas em nosso curso

Técnica	Principais Aplicações	Dimensão	Paradigma
<i>n</i>-Gramas de Caracteres	<i>features</i> para modelos de identif. de plágio, detecção de idioma, atribuição de autor etc.; comparação de strings.	Morfológica	Simbólico
Bag of Words (BoW)	produzir <i>features</i> p/ Naive Bayes e algoritmos de classificação, <i>clustering</i> , regressão etc.	Morfológica	Simbólico
Naïve Bayes Multinomial	análise de sentimentos, classificação de texto	Morfológica	Estatístico
Perceptron	classificação binária de texto	Fonética a Semântica	Estatístico, Neural
Regressão Logística	classificação de texto (binária ou multiclasse)	Fonética a Semântica	Estatístico, Neural
Engenharia de características	produzir <i>features</i> para algoritmos de classificação, <i>clustering</i> , regressão etc.	Fonética a Semântica	Simbólico, Estatístico
StemBR, RSLP	stemming	Morfológica	Simbólico
TF-IDF	produzir <i>features</i> para algoritmos de classificação, <i>clustering</i> , regressão etc.	Morfológica	Estatístico
WordNet	análise semântica, desambiguação de sentido das palavras, similaridade, classificação etc.	Semântica	Simbólico
Word2vec, Tok2Vec	geração de <i>features</i> para classificação, regressão e segmentação de textos, entre outras aplicações	Semântica	Neural

Link para notebook:

- <https://colab.research.google.com/drive/138AjYy2Kk6mSreq5hzaJ8Y9Q65mRxCYJ?usp=sharing>

Referências

- ANUAR, F. M., et al. Semantic retrieval of trademarks based on conceptual similarity. *In: IEEE Transactions on Systems, Man, and Cybernetics: Systems*, v. 46, n. 2, p. 220 – 233, 2016.
- JURAFSKY, D.; MARTIN, J. H. Word Senses and Wordnet. *In: JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing***. 3. ed. (Jan. 12, 2025 draft). [s.l.]: [s.n.], 2025. cap G, p. 1 – 10. Disponível em: < <https://web.stanford.edu/~jurafsky/slp3/> >. Acesso em: 28 abr. 2025.
- Educative, Inc. How to use wordnet in python. **HowDev**. Disponível em: < <https://www.educative.io/answers/how-to-use-wordnet-in-python> >. Acesso em: 28 abr. 2025.
- NLTK. Sample usage for wordnet. **NLTK Project**. Disponível em: < <https://www.nltk.org/howto/wordnet.html> >. Acesso em: 28 abr. 2025.
- OLIVEIRA, H. G., et al. As wordnets do português. *In: **Olso Studies in Languages***, v. 7, n. 1, p. 397 – 424, 2015.
- SENO, E. R. M., DE PAIVA, V.; PINHEIRO, V. Semântica com técnicas simbólicas. *In: CASELI, H. M.; NUNES, M. G. V. **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português***. 3. ed. [s.l.]: BPLN, 2024. cap 9, p. 1 – 8. Disponível em: < <https://brasileiraspln.com/livro-pln/3a-edicao/parte-significado/cap-semantica-simbolica/cap-semantica-simbolica.html> >. Acesso em: 28 abr. 2025.