

TRABALHO EM GRUPO - PARA ENTREGAR E APRESENTAR ATÉ O DIA 13/07/2026

DISCIPLINA: Introdução ao Processamento de Linguagem Natural

PROFESSOR: Eduardo Corrêa Gonçalves

Vocês terão que fazer as seguintes tarefas em GRUPO:

- (1) Estudar sobre o tema **Modelagem de Tópicos** (*Topic Modeling*) no Processamento de Linguagem Natural.
 - Dizer **o que é isso**, explicar o conceito de forma clara
 - Dar 3 ou mais **exemplos de aplicações práticas** em que a modelagem de tópicos pode ser usada, seja nas empresas ou nas pesquisas científicas.
- (2) Estudar o algoritmo LDA – um algoritmo famoso para modelagem de tópicos
 - Explicar conceitualmente como ele funciona (podem omitir detalhes matemáticos)
- (3) Criar um programa para fazer a modelagem de tópicos da base de dados de sátiras (pode ser feito no R)
 - Vocês podem usar a base de dados “bd_satira.csv” que é a base que foi usada no Trabalho 1. Mas ela é bem pequena, só tem 140 observações.
 - Apenas se não der certo com a base acima, usem a base “bd_satira2.csv” que é bem maior
 - Explicar os grupos gerados... tentar interpretar
 - Talvez vocês tenham que tentar diferentes valores de k até chegar em um resultado bom.
 - As bases de dados podem ser encontradas em <https://github.com/edubd/pln>. Como falei, priorizem a “bd_satira.csv” que já temos usado. Mas se for pequena demais para o LDA, mudem para a outra.
- (4) Criar um programa para fazer a modelagem de tópicos com o BERTopic (método neural) e comparar com os resultados do LDA (método estatístico)
- **MUITO IMPORTANTE:**
 - O trabalho é em grupo. A turma inteira vai me apresentar apenas um estudo. No dia 13 poderei fazer uma arguição para diferenciar a nota, ou analisar a apresentação de vocês
 - Os itens (1), (2) e (3) são obrigatórios e valem 90% da nota O item (4) é opcional e vale 10%.
 - Ou seja, se fizerem o (1), (2) e (3) a nota máxima será 9,0. Se fizerem também o (4), a nota máxima é 10